



**MATEMATICKO-FYZIKÁLNÍ
FAKULTA**
Univerzita Karlova

BAKALÁŘSKÁ PRÁCE

Tomáš Karella

Evoluční algoritmy pro řízení heterogenních robotických swarmů

Katedra teoretické informatiky a matematické logiky

Vedoucí bakalářské práce: Mgr. Martin Pilát, Ph.D.

Studijní program: Informatika

Studijní obor: Programování a Softwarové Systémy

Praha 2017

Prohlašuji, že jsem tuto bakalářskou práci vypracoval(a) samostatně a výhradně s použitím citovaných pramenů, literatury a dalších odborných zdrojů.

Beru na vědomí, že se na moji práci vztahují práva a povinnosti vyplývající ze zákona č. 121/2000 Sb., autorského zákona v platném znění, zejména skutečnost, že Univerzita Karlova má právo na uzavření licenční smlouvy o užití této práce jako školního díla podle §60 odst. 1 autorského zákona.

V dne

Podpis autora

Poděkování. Poděkovat Martinovi, Milošovi, Arniimu, Metacentru za počítače

Název práce: Evoluční algoritmy pro řízení heterogenních robotických swarmů

Autor: Tomáš Karella

Katedra: Katedra teoretické informatiky a matematické logiky

Vedoucí bakalářské práce: Mgr. Martin Pilát, Ph.D., Katedra teoretické informatiky a matematické logiky

Abstrakt: Abstrakt.

Klíčová slova: klíčová slova

Title: Evolutionary Algorithms for the Control of Heterogeneous Robotic Swarms

Author: Tomáš Karella

Department: Department of Theoretical Computer Science and Mathematical Logic at Faculty of Mathematics and Physics

Supervisor: Mgr. Martin Pilát, Ph.D., Department of Theoretical Computer Science Mathematical Logic

Abstract: Abstract.

Keywords: key words

Obsah

Úvod	2
1 Evoluční algoritmy	3
1.1 Historie	3
1.2 Co je evoluční algoritmus?	3
1.3 Části evolučních algoritmů	5
1.4 Diferenciální evoluce	9
1.5 Evoluční strategie	10
2 Robotický Swarm	12
2.1 Základní vlastnosti	12
2.2 Použití	13
2.3 Řízení robotických swarmů	14
2.3.1 Genetické programování a stromy chování	14
2.3.2 Genetické algoritmy a neuronová síť	16
2.3.3 Evoluční strategie a neuronová síť	19
3 Simulátor	20
4 Experimenty	22
4.1 Použité technologie	23
4.2 Wood Scene experiment	25
4.2.1 Roboti	27
4.2.2 Vyhodnocování Fitness	29
4.2.3 Podúkoly	29
4.2.4 Výsledky Experimentu	42
4.3 Mineral Scene	44
4.4 Competitive Scene	44
4.5 Shrnutí	44
Závěr	45
Seznam použité literatury	46
Seznam obrázků	49
Seznam tabulek	50
Seznam použitých zkratk	51
Přílohy	52

Úvod

Využití robotických hejn (robotic swarms) patří mezi rentabilní metody pro řešení složitějších úkolů. Existuje řada studií potvrzujících, že velký počet jednoduchých robotů dokáže plně nahradit komplexnější jedince. Dostatečná velikost hejna umožní řešení úloh, které by jednotlivec z hejna provést nesvedl. Navíc robotické hejno přináší několik výhod, díky kvantitě jsou odolnější proti poškození či zničení, neboli zbytek robotů pokračuje v plnění cílů. Dále výroba jednodušších robotů vychází levněji než komplexní jedinců, což přináší nezanedbatelnou výhodu pro práci v nebezpečném prostředí. Hejno také může pokrývat vícero různých úkolů než specializovaný robot, který bude při plnění úkolů, lišících se od typu úloh zamýšlených při konstrukci, mnohem více nemotorný a nejspíše pomalejší. Hejno pokryje větší plochu při plnění úkolů.

Existuje mnoho aplikací robotických hejn, většinou se používají v úlohách týkajících se průzkumu a mapování prostředí, hledání nejkratších cest, nasazení v nebezpečných místech (Jevtić a Andina de la Fuente, 2007). Jako příklad můžeme uvést asistenci záchranným složkám při požáru (Penders a kol., 2011). Mnoho projektů zabývajících se řízením robotického hejna se inspiroje přírodou, používá se analogie s chováním mravenců a jiného hmyzu (David a kol., 2001). Objevují se i hardwarové implementace chování hejn, zmiňme projekty Swarm-bots (professor Marco Dorigo, 2001), Colias (Arvin a kol., n.d.)

Elementárnost senzorů i efektorů jednotlivých robotů vybízí k použití evolučních algoritmů, jelikož prostor řešení je rozlehlý a plnění cílů lze vhodně ohodnotit. Vzniklo několik vědeckých prací popisujících problematiku tohoto tématu (Gomes a kol., 2013) (Ivan a kol., 2013).

Cíl práce

Všechny zmíněné práce používají pro tvorbu řídicích programů evoluční algoritmy (EA) a pracují pouze s homogenními hejny. Cílem této práce je vyzkoušet využití EA na generování chování hejna heterogenních robotů, tedy skupiny agentů, ve které se objevuje několik druhů jedinců a společně plní daný úkol. V rámci práce byl vytvořen program pro simulaci různých scénářů. Pro otestování jejich úspěšnosti v rámci EA, byly zvoleny 3 odlišné scénáře, ve kterých se objevují 2-3 druhy robotů.

Struktura práce

Rozdělení práce je následující. První kapitola je věnována obecnému úvodu do tematiky evolučních algoritmů, kde se podrobněji věnuji evolučním strategiím a diferenciální evoluci, protože oba tyto postupy implementuji v programu pro řešení scénářů.

Dodat zbytek práce

1. Evoluční algoritmy

1.1 Historie

Začneme pohledem do historie Evolučních algoritmů na základě knih Mitchell (1998) a Eiben (2015). Darwinova myšlenka evoluce lákala vědce už před průlomem počítačů, Turing vyslovil myšlenku *genetického a evolučního vyhledávání* už v roce 1948. V 50. a 60. letech nezávisle na sobě vznikají 4 hlavní teorie nesoucí podobnou myšlenku. Společným základem všech teorií byla evoluce populace kandidátů na řešení daného problému a jejich následná úprava způsoby hromadně nazývány jako genetické operátory, například mutace genů, přirozená selekce úspěšnějších řešení, atp.

Rechenberg a Schwefell (1965, 1973) představili *evoluční strategie*, což je metoda optimalizující parametry v reálných číslech, v jejich práci se objevují jako prostředek pro optimalizaci tvaru letadlových křídel. Fogel, Owens, Walsh zveřejnili *evolutionary programming* (evoluční programování), technika využívající k reprezentaci kandidátů konečný automat (s konečným počtem stavů), který je vyvíjen mutací přechodů mezi stavy a následnou selekcí. *Genetické algoritmy* vynalezl Holland v 60. letech a následně se svými studenty a kolegy z Michiganské Univerzity vytvořil první implementaci. U genetických algoritmů, oproti ES a EP, nebylo hlavním cílem formovat algoritmus pro řešení konkrétních problémů, ale přenos obecného mechanismu evoluce jako metody aplikovatelné v inženýrském světě. Princip GA spočívá v transformaci populace chromozomů (př. vektor 1 a 0) v novou populaci pomocí genetických operátorů křížení, mutací a inverze. V 1975 v knize *Adaptation in Natural and Artificial Systems* (Holland, 1976) Holland definoval genetický algoritmus jako abstrakci biologické evoluce spolu s teoretickým základem jejich používání. Někteří vědci ovšem používají pojem GA i ve významech hodně vzdálených původní Hollandově definici. K sjednocení jednotlivých přístupů přispěl v 90. letech John R. Koza, dále jsou všechny metody zahrnuty pod pojmem *Evoluční algoritmy* jako jejich součásti. Dnes se věnuje tématu EA celá řada konferencí a odborných časopisů. Zmíníme ty nejvýznamnější z nich, v kontextu konferencí: GECCO, PPSN, CEC, EVOSTAR, odborné časopisy časopisy, na které bych rád upozornil: Evolutionary Computation, IEEE Transactions on Evolutionary Computation, Genetic Programming and Evolvable Machines, Swarm and Evolutionary Computation


1.2 Co je evoluční algoritmus?

Ač existuje mnoho variant evolučních algoritmů, jak jsme zmínili v krátkém pohledu do historie, spojuje je společná myšlenka populace jedinců uvnitř prostředí s omezenými podmínkami. Jedinci, jinak také nazývaní kandidáti, soutěží o zdroje daného prostředí, tím je docíleno přírodní selekce (přežijí jen ti nejlepší). Pokud budeme mít k dispozici kvalitativní funkci, kterou se snažíme maximalizovat, pak nebude problém vytvořit náhodné jedince z definičního oboru přesně této funkce. Náhodně vzniklé jedince můžeme ohodnotit, tímto způsobem dáme vzniknout abstrakci pro měření *fitness* (z anglického fit: nejvhodnější, zapadající). Z vzniklých a ohodnocených jedinců lze zvolit ty nejlepší pro tvorbu nové

generace jedinců. Tvorba nové generace probíhá kombinováním zvolených rodičů a mutacemi jedinců. Jako kombinaci uvažujeme operátor, který je aplikován na dva a více zvolených kandidátů (proto se jim také říká rodiče) a tvoří jedného a více nových jedinců (také nazývány potomci). Mutace je aplikována pouze na jednoho jedince a její výsledkem je také pouze jednoho jedinec. Tyto dvě operace aplikované na rodičovskou generaci vedou k vytvoření nových kandidátů (potomků, offspring). I tato nová generace je ohodnocena fitness a dále soutěží se starými jedinci na základě fitness o místo v nové generaci, občas také mimo fitness funkce bereme v potaz stáří kandidáta. Popsaný proces je opakován dokud není nalezen kandidát s dostatečně velkou fitness nebo dosáhneme maximálního počtu iterací (bylo dosaženo požadovaného počtu opakování apod). Základy evolučního systému pohání dvě základní hnací síly: *variační operátory*, *selektivní operátory*. Variační operátory zajišťují potřebnou různorodost v populaci a tím tvoří nové cesty k úspěšnému kandidátovi. Oproti tomu selektivní operátory zvyšují průměrnou kvalitu řešení v celé populaci. Kombinací těchto operátorů obecně vede ke zlepšování fitness hodnot v následující generaci. Funkčnost evoluce ověříme snadno, stačí nám k tomu pozorovat zda se fitness v populaci blíží více a více k optimálním hodnotám vzhledem k postupu v čase. Mnoho komponent zapříčiňuje, že EA se řadí ke stochastickým metodám, selekce totiž nevybírá nejlepší jedince deterministicky, i jedinci s malou fitness mají šanci být rodiči následující generace. Během kombinování jsou části rodičů, které budou zkombinovány, také zvoleny pomocí dané pravděpodobností funkce. Podobně je tomu u mutací. Část která bude změněna, je taktéž určena náhodou, stejně tak nové rysy nahrazující staré. EA se řadí mezi populační stochastické prohledávací algoritmy. Vyhodnocení fitness funkce poskytuje heuristický odhad kvality řešení, prohledávání je řízeno variací a selekcí.

Různé dialekty evolučních algoritmů, zmíněné v historickém okénku, splňují všechny tyto hlavní rysy. Liší se pouze v technických detailech. Kandidáti jsou často reprezentováni různě, liší se datové struktury pro jejich uchování i jejich zakódování. Typicky se jedná o řetězce nad konečnou abecedou v případě GA, vektory reálných čísel v ES, konečné automaty v EP a stromy v GP. Důvod těchto rozdílů je hlavně historický. Technicky však lze upřednostnit jednu reprezentaci, pokud lépe odpovídá danému problému, tzn. kóduje kandidáta jednodušeji či přirozenější formou. Pro ilustraci zvolme řešení splnitelnosti (SAT) s n proměnnými, vcelku přirozeně sáhneme po použití řetězce bitů délky n a obsah *itého* bitu označuje, že *itá* proměnná má hodnotu (1) - pravda, (0) - nepravda, proto bychom použili jako vhodný EA genetické algoritmy. Oproti tomu evoluce programu, který hraje šachy, by bylo vhodnější použít derivační strom, kde by vrcholy odpovídaly tahům na šachovnici. Přirozenější by tedy bylo použít GP.

Neopomeňme zmínit ještě dva důležité fakty. Kombinační a mutační operátory musí odpovídat dané reprezentaci, např. v GP kombinace pracuje se stromy (kombinují podstromy ...), zatímco v GA na řetězcích (prohazují části řetězců). A dále oproti variacím musí fitness selekce záviset vždy pouze na fitness funkci, takže selekce pracuje nezávisle na reprezentaci.



Obrázek 1.1: obecný evoluční algoritmus - schéma

1.3 Části evolučních algoritmů

Abychom vytvořili běhu schopný evoluční algoritmus, musíme specifikovat každou zmíněnou část a také inicializační funkci, která připraví první populaci. Pro konečný algoritmus ještě nesmíme opomenout a dodat koncovou podmínku.

- Reprezentace (definice individuí)
- Ohodnocující funkce (fitness funkce)
- Populace
- Selektce rodičů
- Variační operátory (kombinace, mutace)
- Selektce prostředí

Reprezentace

Při tvorbě EA nejdříve musíme propojit prostor původního problému s prostorem řešení, kde se bude vlastní evoluce odehrávat. K docílení propojení je většinou potřeba zjednodušit či vytvořit abstrakci nad aspekty reálného světa (prostor problému), abychom vytvořili vhodný prostor řešení, kde mohou být

jednotlivá řešení ohodnocena. Neboli chceme docílit, aby možná řešení mohla být specifikována a uložena, tak aby s nimi mohl počítač pracovat. Objekty reprezentující možná řešení v kontextu původního problému jsou nazývány *fenotyp*, zatímco kódování na straně EA prostoru se říká *genotyp*. Reprezentace označuje mapování z fenotypů na genotypy, používá se ve významu funkce z fenotypu na genotyp (encode) i genotypu na fenotyp (decode). Při návrhu se snažíme, aby pro každý genotyp existoval nejvýše jeden fenotyp, ne vždy nám to prostor problému umožní. Například pro optimalizační problém, kde množinou řešení jsou celá čísla. Celá čísla tvoří množinu fenotypu a můžeme se rozhodnout pro reprezentaci v binárních číslech. Tedy 18 by byl fenotyp a 10010 jeho genotyp. Prostor fenotypů a genotypů se zpravidla velmi liší a celý proces EA se odehrává pouze v genotypovém prostoru, vlastní řešení dostaneme rozkódováním nejlepšího genotypu po ukončení EA. Jelikož nevíme, jak vlastní řešení vypadá, je nanejvýš vhodné umět reprezentovat všechny možná řešení, že generátor je tudíž kompletní.

- V kontextu původního problému jsou následující výrazy ekvivalentní: fenotyp, kandidát (na řešení), jedinec, individuum (množina všech možných řešení = fenotypový prostor)
- V kontextu EA: genotyp, chromozom, jedinec, individuum (množina, kde probíhá EA prohledávání = genotypový prostor)
- Části individuí jsou nazývány gen, locus, proměnná a dále se dělí na alely, či hodnoty

Populace

Populace je multimnožina genotypů, slouží jako jednotka evoluce. Populace utváří adaptaci a změny, zatímco vlastní jedinci se nijak nemění, jen vznikají noví a nahrazují předešlé. Pro danou reprezentaci je definice populace velmi jednoduchá, charakterizuje ji pouze velikost. U některých specifických EA má populace další prostorové struktury, definované vzdáleností jedinců nebo relacemi sousedních jedinců, což by se dalo připodobnit reálným populacím, které se vyvíjejí v různých geografických prostředích. U většiny EA se velikost populace nemění, což vede k soutěživosti mezi jedinci (zůstanou ti nejlepší). Na úrovni populací pracují právě selektivní operátory. Například zvolí nejlepší jedince aktuální populace jako rodiče následující a nahradí nejhorší jedince novými. Rozmanitost populace - vlastnost, které chceme z pravidel docílit, je měřena jako počet různých řešení v multimnožině. Neexistuje však jediné hledisko, podle kterého lze tuto vlastnost měřit, většinou se používá počet rozdílných hodnot fitness, rozdílných fenotypů či genotypů a také entropie (míra neuspořádanosti). Ovšem musíme mít na paměti, že jedna hodnota fitness v populaci neznamena, že populace obsahuje pouze jeden fenotyp, stejně tak jeden fenotyp nemusí odpovídat jednomu genotypu apod.

Selekce rodičů

Rodičovská selekce, někdy také partnerská selekce, vybírá lepší jedince jako rodiče pro příští generaci. Jedinec se stává rodičem, pokud byl zvolen k aplikaci variačních operátorů a tím dal vzniknout novým potomkům. Společně se selekcí

přeživších je rodičovská selekce zodpovědná za zvedání kvality v populacích. Rodičovská selekce je v EA většinou pravděpodobnostní metoda, která dává jedincům s větší kvalitou mnohem větší šanci být vybrán než těm s nízkou. Nicméně i jedincům s nízkou kvalitou je často přidělena malá nenulová pravděpodobnost pro výběr, jinak by se celé prohledávání mohlo vydat slepou cestou a zaseknout se na lokální optimu.

Variační operátory

Hlavní úlohou variačních operátorů (mutace, rekombinaci) je vytváření nových individuí ze starých. Z pohledu Generate Test algoritmů spadají variační operátory do právě do Generate části. Obvykle je dělíme na dva typy podle jejich arity, jedná se o unární (Mutace) a *nární* (rekombinace) operátory.

Mutace

Ve většině případů myslíme unárním variačním operátorem mutace. Tento operátor je aplikován pouze na jeden genotyp a výsledkem je upravený potomek. Mutace řadíme mezi stochastické metody, výstup (potomek) totiž závisí na sérii náhodných rozhodnutí. Však mutace není vhodné pojmenování pro všechny variační operátory, například pokud se jedná o heuristiku závislou na daném problému, která se chová systematicky, hledá slabé místo a následně se jej snaží vylepšit, v tomto případě se nejedná o mutaci v pravém slova smyslu. Obecně by mutace měla způsobovat náhodné a nezaujaté změny. Unární variační operátory hrají odlišnou roli v rozdílných EA opět díky historicky oddělenému vývoji. Zatímco v GP se nepoužívají vůbec, V GA mají velmi důležitou roli a v EP se jedná o jediný variační operátor. Díky variačním operátorům aplikovaným v jednotlivých evolučních krocích dostává prohledávací prostor topologickou strukturu. Existují teorie podporující myšlenku, že EA (s dostatečným časem) naleznou globální optimum daného problému opírající se právě o tuto topologickou strukturu a také spoléhají na fakt, že může vzniknout každý genotyp reprezentující možné řešení. Nejjednodušší cesta ke splnění těchto podmínek vede právě přes variační operátory. U mutací tohoto například dosáhneme, když povolíme, aby mohly skočit kamkoliv, tzn. každá alela může být zmutována na jakoukoli další s nenulovou pravděpodobností.

GP
podle
Mar-
tina ob-
sahují
mutace

Rekombinace

Rekombinace, také nazývána křížení, je binární variační operátor. Jak název napovídá, spojuje informace ze dvou rodičů (genotypů) do jednoho nebo dvou potomků. Stejně jako mutace patří rekombinace k stochastickým operátorům. Rozhodnutí, jaké části budou zkombinovány a jakým způsobem toho bude docíleno, závisí na náhodě. Role rekombinace se znovu liší v rozličných EA, v GP se jedná o jediné variační operátory, v EP nejsou použity vůbec. Existují rekombinační operátory s vyšší aritou (tzn. používající více než dva rodiče) a jsou také jednoduché na implementaci. Dokonce několik studií potvrdilo, že mají velmi pozitivní vliv na celou evoluci, ale nemají tak hojné zastoupení, nejspíše proto, že neexistuje biologický ekvivalent. Rekombinace funguje na jednoduchém principu,

GP
podle
Mar-
tina ob-
sahují
mutace

slučuje dvě individua a produkuje jednoho či více potomků, kteří kombinují jejich vlastnosti, tedy potomek by měl být úspěšnější než jeho rodiče. Tento princip podporuje fakt, že po tisíciletí se aplikací rekombinace na rostliny a zemědělská zvířata mnohokrát podařilo vytvořit nové jedince s vyšším výnosem či jinými výhodnými vlastnostmi (odolnost proti škůdcům atd). Evoluční algoritmy vytváří množství potomků náhodnou rekombinací a doufáme, že zatímco malá část nové generace bude mít nežádoucí vlastnosti, většina se nezlepší ani si nepohorší a konečně další malá část předčí jejich rodiče. Na naší planetě se sexuálně (kombinací dvou jedinců) rozmnožují pouze vyšší organismy, což vzbuzuje dojem, že rekombinace je nejvyšší forma reprodukce. Neopomeňme, že variační operátory jsou závislé na reprezentaci (genotypu) jedinců. Např. pro genotypy bitových řetězců může použít bitovou inverzi jako vhodný mutační operátor bude-li ovšem genotyp strom musíme zvolit nějaký jiný.

Selekce prostředí

Selekce prostředí, někdy také nazývána selekce přeživších, jak název napovídá má blízko k selekci rodičů, odlišuje jednotlivá individua na základě jejich fitness hodnoty. Oproti rodičovské selekci ji však používáme v jiné části evolučního cyklu. Selekcí prostředí spouštíme hned po vytvoření nových potomků. Jelikož velikost populace kandidátů bývá skoro vždy konstantní, je nutné rozhodnout, které kandidáty zvolíme do další generace. Toto rozhodnutí většinou závisí na hodnotě fitness jednotlivých kandidátů, také se často hledí na dobu vzniku daného kandidáta. Dobou vzniku myslím generaci v které daný jedinec vznikl. Na rozdíl od rodičovské selekce, která bývá stochastická, bývá selekce prostředí deterministickou metodou. Uvedme dvě nejběžnější metody, obě kladou největší důraz na fitness. První vybírá nejlepší segment z množiny nových potomků i z původní generace nezávisle, druhá dělá totéž jen z množiny nových potomků. Selekcí prostředí je uváděna i pod názvem „záměnná“ strategie (replacement strategy). Selekcí prostředí (přeživších) se víceméně používá, pokud je množina nových potomků větší než velikost generace a záměna využíváme když je nových potomků velmi málo.

Inicializace populace

Inicializace populace zastává důležitý úkol a to vytvořit první generaci kandidátů. Její implementace bývá ve většině EA velmi jednoduchá. První generace je vygenerována čistě náhodně. Principiálně by se zde dalo využít nějaké heuristiky k vytvoření vyšší fitness v první generaci, ovšem musela by zohledňovat řešený problém. Jestli tento postup stojí za výpočetní čas, velmi záleží na konkrétní aplikaci EA. Ovšem existují obecná doporučení, která se touto otázkou zabývají.

Ukončovací podmínka

Rozlišme dvě varianty vhodné ukončovací podmínky. Pokud řešený problém má známou optimální hodnotu fitness, potom v ideálním případě ukončovací podmínkou je řešení s touto fitness. Pokud jsme si vědomi, že náš model oproti modelovanému prostředí obsahuje nutná zjednodušení nebo by se v něm mohly vyskytovat nežádoucí šумы, lze se spokojit s řešením, které dosáhlo optima fitness

s přesností $\epsilon > 0$. EA díky své stochastičnosti většinou nemohou garantovat dosažení takovéto hodnoty fitness, takže ukončovací podmínka by nemusela být nikdy splněna a algoritmus by běžel věky. Kdybychom vyžadovali konečnost algoritmu, musíme rozšířit ukončovací podmínku. Zatímto účelem se nejběžněji používají následující rozšíření:

1. Byl překročen čas vyhrazený pro počítání na CPU
2. Celkový počet evaluací fitness přesáhl svůj předem daný limit
3. Zlepšení fitness v dané časovém bloku (měřenému počtem generací, či evaluací) klesla pod přípustný práh
4. Rozmanitost v populaci nedosahuje předem určených hodnot

Ukončovací podmínka bývá prakticky disjunkce předchozích tvrzení. Může se stát, že optimum známé není. Pak se používá pouze zmíněných podmínek nebo se smíříme s nekonečností algoritmu a ukončíme jeho běh manuálně.

1.4 Diferenciální evoluce

První verze diferenciální evoluce se objevila jako technický report Storn a Price (1997). Tento evoluční algoritmus popíši podrobněji, protože je jedním z klíčových algoritmů mého řešení.

Charakteristické vlastnosti

DE dostala své jméno hlavně díky změnám obvyklých reprodukčních operátorů v EA. Diferenciální mutace, jak jsou mutace v DE nazývány, z dané populace kandidátů vektorů v \mathbb{R}^n vzniká nový mutant \bar{x}' přičtením pertubačního vektoru (perturbation vector) k existujícímu kandidátovi.

$$\bar{x}' = \bar{x} + \bar{p}$$

Kde pertubační vektor \bar{p} je vektor rozdílů dvou náhodně zvolených kandidátů z populace \bar{y} a \bar{z} .

$\bar{p} = F \cdot (\bar{y} - \bar{z})$. Faktor škálování $F > 0$, $F \in \mathbb{R}$, který kontroluje míru mutace v populaci. Jako rekombinační operátor v DE slouží uniformní křížení, pravděpodobnost křížení je dána $C_r \in [0,1]$, definuje šanci jakékoli pozice v rodiči, že odpovídající alela potomka bude brána z prvního rodiče. DE také upravuje křížení, neboť jedna náhodná alela je brána vždy z prvního rodiče, aby nedocházelo k duplikaci druhého rodiče.

V hlavních implementacích DE reprezentují populace spíše listy, odpovídají lépe než množiny, umožňují referenci *itého* jedince podle pozice $i \in 1, \dots, \mu$ v listu. Pořadí kandidátů v této populaci $P = \langle \bar{x}_1 \dots \bar{x}_i \dots \bar{x}_\mu \rangle$ není závislé na hodnotě fitness. Evoluční cyklus začíná vytvořením populace vektorů mutantů $M = \langle \bar{v}_1 \dots \bar{v}_\mu \rangle$. Pro každého nového mutantu \bar{v}_i jsou zvoleny 3 vektory z P , base vektor a dva definující pertubační vektor. Po vytvoření populace mutantů V , pokračujeme tvorbou populace $T = \langle \bar{u}_1, \dots, \bar{u}_\mu \rangle$, kde \bar{u}_i je výsledek křížení \bar{v}_i a \bar{x}_i (všimněme si, že je zaručené, že nezreplikujeme \bar{x}_i). Jako poslední aplikujeme selekci na každý pár \bar{x}_i a \bar{u}_i a do další generace vybereme \bar{u}_i pokud $f(\bar{u}_i) \leq f(\bar{x}_i)$ jinak \bar{x}_i .

DE algoritmus upravují 3 parametry, škálovací faktor F , velikost populace μ (obvykle značen NP v DE literatuře) a pravděpodobnost křížení C_r . Na C_r lze také pohlížet jako na míru mutace, tzn. alela nebude převzata od mutanta.

Vlastnosti diferenciální evoluce:

Reprezentace:	vektor \mathbb{R}^n
Rekombinace:	uniformní křížení
Mutace:	diferenční mutace
Rodičovská selekce:	uniformní náhodné selekce 3 nezbytných vektorů
Selekce prostředí:	deterministická selekce elity (dítě vs rodič)

Tabulka 1.1: diferenciální evoluce - souhrnné vlastnosti

Varianty DE:

Během let, vzniklo a bylo publikováno mnoho variant DE. Jedna z modifikací zahrnuje možnost base vektoru, když vytváříme mutantské populace M . Může být náhodně zvolen pro každé v_i , jak bylo řečeno, ale také lze využít jen nejlepšího vektoru a nechat změny na pertubačním vektoru. Další možnost otevírá použití více pertubačních vektorů v mutačním operátoru. Což by vypadalo následovně: $\bar{p} = F(\bar{y} - \bar{z} + \bar{y}' - \bar{z}')$, kde $\bar{y}, \bar{z}, \bar{y}', \bar{z}'$ jsou náhodně vybrány z původní populace.

Abychom odlišili různé varianty, používá se následující notace DE/a/b/c, kde a specifikuje base *vektor(rand, best)*, b specifikuje počet diferenčních vektorů při vzniku pertubačního vektoru, c značí schéma křížení (bin=uniformní). Takže podle této notace by základní verze DE byla zapsána takto: DE/rand/1/bin.

1.5 Evoluční strategie

Evoluční strategie (evolution strategies) byly představeny v německém článku Rechenberg (1981), původně byl určen pro optimalizaci tvarů křídel. Jedná se o evoluční algoritmus cílící na optimalizaci vektorů reálných čísel. Objevili si dvě schémata (1+1) a (1, 1). Starší (1+1) (one plus one ES) vytvářejí potomka mutací a to přičtením náhodných nezávislých hodnot ke složkám rodičovského vektoru, následně je potomek přijat, pokud získal lepší fitness než jeho rodič. Jako další vznikl (1,1) (one comma one ES), které neimplementovalo elitismus, tzn. měnila vždy rodiče potomkem. Mutační funkce bere náhodná čísla z Normálního rozdělení s se střední hodnotou 0 a odchylkou σ . Pro velikost mutačního operátoru (mutation step size) se také používá symbol: σ . Vylepšení původního algoritmu bylo představeno v 70. letech, jedná se o koncept multisložkových ES, které se skládají ze μ jedinců (velikost populace) a λ jedinců vygenerovaných během jednoho cyklu. Opět tento koncept existuje ve dvou verzích (μ, λ) a $(\mu + \lambda)$. Zatímco běžné rekombinační schéma zahrnuje dva rodiče a jednoho potomka, intermediate křížení, které se u ES používá, zprůměruje hodnoty z rodičovských alel. Tímto způsobem můžeme používat i rekombinační operátory s použitím více než dvou rodičů, tyto operátory se nazývají globální rekombinace. Konkrétně se na potomkovi podílí λ rodičů. V praxi se preferuje (μ, λ) před $(\mu + \lambda)$, protože zahazuje všechny rodiče, tím pádem se snadno nezastaví na lokálním optimu, (μ, λ)

se zvládá lépe adaptovat i při hledání pohyblivého optima. Pro typické použití se používá poměr 1:4 a 1:7.

Vlastnosti evolučních strategií:

Reprezentace:	vektor \mathbb{R}^n
Rekombinace:	intermediary křížení
Mutace:	přičítání náhodných hodnot z norm. rozdělení
Rodičovská selekce:	uniformní náhodná
Selekce prostředí:	(sigma,lambda) nebo (sigma + lambda)

Tabulka 1.2: evoluční strategie - souhrnné vlastnosti

Možno
přidat
pseudo-
kód

2. Robotický Swarm

V češtině se také používá výraz Rojová Robotika nebo Robotický Roj, v angličtině je známý pod pojmem Swarm Robotics. Myšlenka Robotického Swarmu pochází podobně jako u Genetických Algoritmů z inspirace matkou Přírodou. Podle souhrnu (Tan a Zheng, 2013) popíši základní myšlenku RS.

2.1 Základní vlastnosti

Motivací pro použití RS může být chování živočichů na Zemi. Zaměříme se na skupiny živočichů jako jsou mravenci, včely, ryby dokonce i některé savce. Pokud bychom vložili do prostředí jednotlivce z některé ze zmíněných skupin, nebude schopen konkurovat nepřátelskému prostředí a nejspíše příliš dlouho nepřežije. Na druhou stranu, když budeme uvažovat celé společenství, tak se nám ze slabého jedince stane velmi adaptivní, odolný a rychle se vyvíjející roj. Podobnému účinku bychom se chtěli přiblížit v RS. Pro relativně jednoduchého robota, který není schopen plnit obtížný úkol, se pokusíme použít vícero robotů stejného typu, kteří společně zadaný úkol vyřeší. Navíc chceme těžit ze všech výhod hejna.

Jako nejčastější výhody RS oproti jednomu robotovi se nejčastěji uvádějí:

1. Paralelita - Díky malé ceně jedince, si můžeme dovolit velkou populaci jedinců. Malou cenou jedince v ES myslíme, že se jedná o jednoduchého robota s nízkou pořizovací cenou. V kontextu živočichů můžeme uvažovat množství energie, jídla pro tvorbu takového jedince. Velká populace nám umožňuje řešit vícero úkolů naráz, také na velké ploše. Zvláště pro vyhledávací úkoly ušetříme nemalé množství času.
2. Škálovatelnost - Změna velikosti populace hejna neovlivní chování ostatních jedinců. Samozřejmě plnění úkolu bude rychlejší či pomalejší, ale původní hejno bude stále plnit původní úkol. Tím pádem můžeme celkem snadno upravovat velikost populace bez větší obtíží. V přírodě můžeme pozorovat, že smrt jednotlivých mravenců-dělníků znatelně neovlivní práci celého mraveniště. Nově narození mravenci se mohou vydat do práce, zatímco zbytek mraveniště nemění činnost.
3. Houževnatost - Související se škálovatelností, jen v tomto případě máme na mysli necílenou změnu populace. Jako v předchozím příkladu, u smrti mravenců, část robotů ES může selhat z rozličných důvodů, zbytek hejna však bude pokračovat k cíli, i když ve výsledku jim bude jeho dosažení trvat o něco déle. Což se nám může vyplatit v nebezpečných prostředích.
4. Ekonomické výhody - Cena návrhu a konstrukce jednoduchých hejn robotů vyjde většinou levněji než jeden specializovaný robot schopný uspokojit stejné požadavky. V dnešním světě vychází výroba ve velkém množství mnohem levněji než tvorba jednoho drahého konkrétního robota.
5. Úspora energie - Díky menší velikosti a složitosti jednotlivých robotů vyžadují mnohem menší množství energie. Což má za důsledek, že si u nich můžeme dovolit energetickou rezervu na delší čas. Navíc když je pořizovací

cena jednoho robota menší než náklady na dobití, můžeme díky škálovatelnosti pouze připojit nové roboty, což u drahého robota jde málokdy.

6. Autonomie a Decentralizace - V kontextu RS musí každý jedinec hejna jednat autonomně, jedinci nejsou řízeny žádnou autoritou. Takže umí pracuje i při ztrátě komunikace. Opět se vychází z chování živých organismů. Pokud se chovají jedinci hejna dostatečně kooperativně, mohou pracovat bez centrálního řízení, důsledkem toho se stává celé hejno ještě flexibilnější a odolnější, hlavně v prostředích s omezenou komunikací. Navíc hejno mnohem rychleji reaguje na změny.

Mimo RS existuje i řada jiných přístupů, které se inspirovaly životem hejn v přírodě. Občas jsou zaměňovány za RS, nejčastěji se jedná o multi-agentní systémy a senzorové sítě (sensor networks). V následující tabulce jsou popsány jejich nejklíčovější vlastnosti.

	Robotická hejna	Multi-robotické systémy	Senzorové sítě	Multi-agentní systémy
Velikost populace	Variabilní ve velkém rozsahu	Malá	Fixní	V malém rozsahu
Řízení	decentralizované a autonomní	centralizované	centralizované	centralizované
Odlišnosti	většinou homogenní	většinou heterogenní	homogenní	homogenní nebo heterogenní
Flexibilita	vysoká	nízká	nízká	střední
Škálovatelnost	vysoká	nízká	střední	střední
Prostředí	neznámé	známé nebo neznámé	známé	známé
Pohyblivost	ano	ano	ne	vyjímčně

Tabulka 2.1: Porovnání systémů s více agenty

Také se liší svojí aplikací Robotická hejna se nejčastěji používají ve vojenských, nebezpečných úkolech a také pro řešení ekologických katastrof. Multi-robotické systémy potkáváme v transportních, skenovacích úkolech, dále pro řízení robotických fotbalových hráčů. Oproti tomu nejčtenější využití senzorových sítí zasahuje do medicínské oblasti, ochrany životního prostředí. Multi-agentní systémy zase nejvíce zasahují do řízení síťových zdrojů a distribuovaného řízení.

2.2 Použití

Existuje několik vědeckých prací, které studují a navrhuji použití RS v reálném nasazení.

Některé jsem zmínil už v úvodu této práce, jako například hasičům asistující roboty (Penders a kol., 2011). Kde si robotické hejno klade za cíl usnadnit a podpořit navigaci lidem v nebezpečném prostředí. Jejich využití je ilustrováno záchranou misí ve velkém skladišti. Hasiči mají díky kouři velmi omezenou viditelnost. Tím pádem se lokalizace přeživších, epicenter požárů a další důležitých bodů stává obtížným a zdraví ohrožujícím úkolem. Robotické hejno tedy může prozkoumat celý prostor před vlastním zásahem. Při zásahu ještě asistovat hasičům při orientaci v prostoru. Nezřídka se stává, že zasahující hasič zahyne, protože se v hustém dýmu v objektu ztratil.

Robotická hejna se také ukázala jako užitečná u ekologický pohrom. Španělští vědci testovali jejich použití při úniku ropy (Aznar a kol., 2014), či při hledání centra radiace (Bashyal a Venayagamoorthy, 2008).

V prvně zmíněném příkladu autoři mapovali znečištění mořské vody. Dokonce při plavbách bez defektů se do moře uvolňuje palivo, ropa a další nebezpečné látky. Očekává se, že s rostoucí námořní dopravou se rozrostou tyto lokální znečištění ve vážnou hrozbu. Aktuální systémy monitorující znečištění při katastrofách tankerů jsou pro toto využití příliš drahé. Autoři proto navrhnou použití hejna dronů, které bude dokumentovat velké vodní plochy a bude schopno odhalovat případné nebezpečí a větší koncentrace cizích látek. Dokonce budou moci na základě získaných informací sledovat znečišťovatele.

Po jaderné katastrofě se stává explorační zamořené oblasti v podstatě nemožným úkolem pro lidské průzkumníky. Právě monitorování radiací postiženým územím se stala motivací pro práci (Bashyal a Venayagamoorthy, 2008). Ve zmiňované práci se autoři soustředí na porovnávání autonomních robotických hejn a RH komunikující s člověkem. V rámci výsledků ukazují, výhody použití robotického hejna pro hledání centra radiace a také že RH interagující s lidmi dosahují lepších výsledků.

Několik prací nezůstalo pouze u simulací a také využívali RS u fyzických robotů. Hlavní motivací pro tuto práci byl fakt, že většinou se řízení RS vytváří a hlavně testuje pouze v uzavřeném a simulovaném prostředí. Tvůrci se rozhodli pro reálné použití na moři, kde nemohou prostředí jakkoli ovládat či kontrolovat. Snaží se tím ukázat, že i přes šumy a neočekávané situace, RS je stabilní a použitelné pro aplikaci ve skutečném světě. Celé hejno se skládalo z deseti robotů. Jednalo se o malé lodičky s délkou přibližně 60 cm a nízkou pořizovací cenou okolo 300 eur. Každý robot byl vybaven GPS, WIFI, kompasem. Chování bylo připraveno pomocí evolučních algoritmů v simulaci, konkrétně autoři používají neuroevoluci NEAT, jejich simulace obsahovala 4 podúkoly: navádění, shlukování, rozptylování a monitorování prostředí. Poté bylo stvořené řízení ohodnoceno na vodní ploše. Prezentované výsledky vypadají velmi slibně, chování a úspěšnost řízení se velmi blíží mezi simulací a reálným nasazením. Také potvrzují přítomnost výhodných vlastností ze simulací v reálném světě, jedná se o robustnost, flexibilitu, škálovatelnost. V neposlední řadě také úspěšnost skládání jednoduchých podúkolu do komplexního chování v rámci hejna, které řeší složitý hlavní cíl. (Duarte a kol., 2016).

2.3 Řízení robotických swarmů

Chování swarmů se řadí mezi velmi obtížné úkoly pro svět informatiky. Pro reprezentaci chování se využívá *neuronových sítí*, které se optimalizují pomocí nastavování vah jednotlivých perceptronů, neboť se jedná o velký prostor vstupních informací ze senzorů a prostor pro interakci s prostředím je taktéž velmi rozsáhlý. Přímé prohledávání takto obřího prostoru nepřichází v úvahu, proto v poslední době získávají na oblibě evoluční algoritmy. Mezi nejvíce používané patří evoluční strategie, či genetické programování.

2.3.1 Genetické programování a stromy chování

V práci „Evolving behaviour trees for Swarm robotics“ (Jones a kol., 2018) se autoři zaměřují na využití genetického programování pro vytvoření chování robotického hejna. Pro řízení hejna navrhnou vcelku zajímavé využití stromů chování

(SC)(behaviour tree), které mají uplatnění především v herním průmyslu pro akce charakterů, které nejsou ovládány hráčem. Jako optimalizační algoritmus zvolili genetické programování.

Strom chování je strom, jehož listy interagují s prostředím, vnitřní vrcholy spojují tyto akce dohromady a tvoří rozhodovací a závislostní pravidla. Celý strom je vyhodnocován v pravidelných intervalech, v práci se značí jako *tick*. Opírají se o článek (Shoulson a kol., 2011), kde bylo ukázáno, že SC může plnohodnotně reprezentovat konečné automaty, dokonce i když budeme používat pravděpodobností konečné automaty. Jako jedince z hejna zvolili Kilobot, které byl představen Rubensteinem v (Rubenstein a kol., 2014). Kilobot se pohybuje pomocí dvou vibračních motorů, komunikují přes infračervený kanál, v prostředí se orientují pomocí foto detektoru a signalizují pomocí LED diod s barevným spektrem. Následující části zjednodušují komunikaci s efekty robota a nad nimi optimalizováno SC.

Efektor/Senzor	Read or Write	Popis
motor	W	vypnut, vřed, vlevo, vpravo
přídavná paměť	R&W	libovolná hodnota
vysílač signálu	R&W	vysílá při větší hodnotě než 0.5
přijímač signálu	R	1 pokud přijímá signál
detektor potravy	R	1 pokud světelný snímač vidí potravu
nosič jídla	R	1 pokud nese jídlo
hustota robotů	R	hustota Kilobotů v blízkosti
$\delta_{hustota}$	R	změna v hustotě
$\delta_{vzdálenost_{potrava}}$	R	změna ve vzdálenosti k potravě
$\delta_{vzdálenost_{hnízdo}}$	R	změna ve vzdálenosti k hnízdu

Tabulka 2.2: Parameterizing behavior trees, Motion in Games - podoba stromů

Tyto akce pak odpovídají listům v SC, vnitřní vrcholy mohou být kompoziční: *seqm*, *selm*, *probm* a tyto mohou mít 2 až 4 syny. Informace procházející mezi vrcholy mohou být následujícího druhu *success*, *failure*, *running*. Zpracovávají informace následujícím způsobem posílají tik do každého syna dokud od nějakého nepřijde hodnota *failure* nebo tik proběhne na všech synech. Pokud proběhne úspěšně tik u všech synů vrací *success*, *failure* jinak. Oproti tomu *selm* vysílá tik, dokud mu nějaký syn nevrátí hodnotu *success* nebo všichni synové provedli tik, pokud se nevrátí jediná hodnota *success*, tak vrací *failure*, v opačném případě *success*. Od obou se liší *probm*, ten s danou pravděpodobností vybere jednoho syna a vrátí jeho odpověď. Vrchol, který má alespoň jednoho syna se statusem *running* vrací stejnou hodnotu.

Vrcholy jen s jedním synem patří do jedné z následujících kategorií: *repeat*, *successed*, *failed*. Vrchol *repeat* vrací tik svým synům, s daným počtem pokusů, dokud nedostane hodnotu *success*. Následující dva vrcholy vrací konstantní odpověď na tik dle svého jména, i přesto pošlou tik svému následníkovi.

Poslední skupinu vrcholu tvoří tzv. akční vrcholy *ml*, *mr*, *mf*, což ve stejném pořadí jsou: zatoč vlevo, zatoč vpravo, jeď kupředu. Vrcholy pohybu při prvním tik u vrací *running* při druhém *success* K akčním vrcholům také patří *if*, který

implementuje porovnávání synů a vrací *success*, pokud porovnání platí. Poslední z akčních vrcholů je *set*, který nastavuje danou hodnotu synům.

V prostředí jsou s konstantní frekvencí prováděny tzv. „update“ cykly. Každý cyklus se skládá ze třech částí po sobě jdoucích částí.

1. Spočítají se hodnoty v synech z vysílaných signálů a prostředí.
2. Na SC je proveden tik, což čte a zapisuje hodnoty do synů.
3. Pohybové motory jsou aktivovány a vysílání je upraveno, oboje dle zapsaných hodnot do synů.

Jako zátěžový test používají obvyklý scénář, který spočívá v hledání potravy a jejím odvážení zpět do hnízda. Fitness se hodnotí podle vzdálenosti doneseného jídla, čím blíže k hnízdu tím lépe. Jako optimalizační metodu autoři vybrali genetické programování a používají DEAP knihovnu (Fortin a kol., 2012). Celá populace velikosti n_{pop} je ohodnocena fitness, každý jedinec se hodnotí podle 10 simulací, každá simulace má jinou startovní konfiguraci. Roboti startují vždy na poli o velikosti 5x5, jejich orientace je vybírána náhodně. Běží 300 simulovaných sekund, frekvence update cyklu 8Hz pro vnímání prostředí a u ovladačů s 2Hz. Používané genetické programování implementuje elitismus přenáší n_{elite} nejlepších jedinců do další generace, zatímco zbylá část je zvolena turnajovou selekcí s velikostí t_{size} . Křížící (rekombinační) operátor, který kříží části stromů, je aplikován s pravděpodobností p_{xover} na všechny páry vybrané turnajovou selekcí. Na vzniklé páry se aplikují 3 mutační operátory.

1. S pravděpodobností p_{mutu} je náhodný vrchol stromu vyměněn za nový náhodně vytvořený
2. S pravděpodobností p_{mutv} je náhodná větev stromu a je vyměněna za náhodně zvolený terminál (vyskytující se na této větvi)
3. S pravděpodobností p_{mutn} je náhodný vrchol vyměněn za nový, ale se stejným počtem argumentů
4. S pravděpodobností p_{mute} je náhodná konstanta vyměněna za jinou náhodnou hodnotu

Krom simulace 25 nezávislých běhů evoluce. Také byly otestovány algoritmy na reálných strojích, vytrénované chování bylo otestováno 20 běhy s rozdílnou startovací pozicí a ohodnocení stejnou fitness.


Výsledky simulace byly více než uspokojivé v simulační části si hejno vedlo o trochu lépe 0.075 z maximální hodnoty 0.12 (minimum 0) a co se týče reálného nasazení vygenerovaného chování 0.058. Což opravdu není velký rozdíl, když přihlídneme k tomu, že evoluce probíhala čistě na simulační rovině.

2.3.2 Genetické algoritmy a neuronová síť

Cagri a Yalcin používají ve své práci (Yalcin, 2008) práci neuronových sítí místo SC a pro nastavení vah genetického algoritmu. Shodují se s Winfieldem a

jeho kolegy, že evoluce mnoho chování robotického hejna přináší zajímavých strategií, která mohou být mnohem komplexnější než explicitně vytvořené chování. Popisují však také obtížnosti použití evoluce, zvláště volbu evolučního algoritmu a efektivnost celého výpočtu.

Využívají již existujícího simulátoru Cobot2D, pro všechny experimenty bylo použita mapa bez překážek velikosti 400x400. Roboti se pohybují pomocí dvoukolečkových motorů, orientují se 4 infračervenými senzory a 4 zvukovo-směrovými senzory, v jejich středu je umístěn všesměrový zvukový vysílač. Vysílače mají pevný rozsah kruhu vysílání a dynamickou sílu. Zvukové senzory se rozhodují pouze podle signálů, jejichž vysílače spadají do 90° výseče od senzoru a také jejich vzdálenost musí být menší než daná konstanta. Síla signálu se zmenšuje směrem od vysílače a senzory vrací součet sil signálů. Infračervené senzory skenují úsečku dané velikostí a vrací vzdálenost k nejbližšímu průsečíku. V rámci simulace jsou generovány náhodné šумы pro každou interakci s prostředím, aby se simulace přiblížila co nejvíce reálnému nasazení. Pro ovládání robota byla navržena neuronová síť, která má 8 vstupů (4 pro infra-senzory a 4 pro zvukové) a 3 výstupy a není zde žádná skrytá vrstva. Náčrso robota a jeho ovládací neuronové síť můžete vidět na obrázku.



Obrázek 2.1: Cobot2D - náčrso robota, zdroj : (Yalcin, 2008)

Genetický algoritmus:

1. Inicializuj populaci P 100 jedinců a každý jedinec reprezentován váhovým vektorem
2. Nastav všem váhovým vektorům z populace náhodné floating point hodnoty v intervalu $\in (-1,1)$
3. $G_{current}$ nastav na 0(id generace)
4. Dokud $G_{current} < 100$ Prováděj
 - (a) Pro každý vektor $w \in P$
 - i. Vytvoř 5 simulací prostředí s 10 roboty a orientovanými náhodně
 - ii. Přiřaď každému roboty jako ovladač neuronovou síť s váhami w
 - iii. Spust simulaci pro 5000 kroků
 - iv. Každé simulaci spočítej fitness pro skupinu robotů
 - v. Průměr z vypočítaných fitness z předchozího kroku přiřaď jako fitness vektoru w
 - (b) Setříd vektory podle jejich fitness
 - (c) Zvol nejlepších 20 jako elitu P_e
 - (d) Zvol náhodně 80 vektorů P_c a aplikuj na ně křížení (prohazuje 1/3 vektoru a shodné páry)
 - (e) Zvol náhodně 40 vektorů z P_c a aplikuj mutační operátor (přičtení náhodného čísla z $(-1,1)$)
 - (f) Zvol $P = P_c \cup P_e$
 - (g) Zvyš $G_{current}$ o jedna.
5. Vrať jedince, který má z P největší fitness

Fitness Funkce: První použitá $fitness_1$ z tohoto experimentu, obrácená hodnota průměrné vzdálenosti do středu robotické skupiny.

$$fitness_1 = 1/(1/n \sum_{r=1}^n d_{rc})$$

Kde n je počet robotů v robotické skupině, r je robotův index, d_{rc} je euklidovská vzdálenost mezi r a středem robotické skupiny c .

Druhá $fitness_2$ používá metodu *inverse of hierarchical social entropy* (Balch, 2000). Tato metoda počítá kompaktnost skupiny, tím že hledá každou možnou skupinku (cluster) pomocí změn maximální vzdálenosti h mezi jedinci ze stejného clusteru. Přidávají ještě rozšíření od *Shannon's information entropy*, jenž používá pevné h . Toto rozšíření je definováno:

$$H(h) = - \sum_{k=1}^M p_k \log_2(p_k)$$

H se nazývá entropie, p_k je proporce jedince z clusteru k , M je počet clusterů pro dané h . Konečně celý předpis daný Balchem vypadá následovně:

$$fitness_2 = \int_0^\infty \frac{1}{H(h)dh}$$

Použití neuronových sítí a genetického algoritmu se ve výsledku ukázalo jako vhodný prostředek pro učení robotického hejna, neboť se vygenerované chování obstojně shlukuje do úzkých skupin. Definují další tzv. cost funkci pro měření úspěchu nalezených chování, aby mohli porovnávat funkce fitness. A $fitness_2$ se ukazuje jako účinnější.

2.3.3 Evoluční strategie a neuronová síť

V článku *Self-organised path formation in a swarm of robots* (Sperati a kol., 2011) aplikují pro řízení robotických hejn evoluční strategie. Jako cíl si článek klade problém průzkumu a navigace v neznámém prostředí v kontextu robotických hejn. Experiment, který měl otestovat uvedené vlastnosti robotického hejna, spočíval v co nejrychlejším přesunu celého hejna mezi dvěma prostory v neznámém prostředí.

Pro simulaci bylo využito upravené verze OS Evorobota a jako model jedince z hejna e-puck robot (Mondada a kol., 2009). Tento robot se pohybuje pomocí dvou-koleček, má 8 infračervených senzorů, navíc jeden infračervený senzor na povrch a jeden rozpoznávací barvy vpředu (v tomto případě černobílé prostředí). Navíc mu byla přidělena LED vpředu s modrou barvou a červenou vzadu, která může zapínat a vypínat dle potřeby, a také má snímač barev na vrchu.

Pro ovládání robota zvolili autoři neuronovou síť se 13 vstupy (8 pro infračervené senzory, 1 pro binární podlahový senzor (bílá vs. černá), 4 pro binární vizuální snímače), dále 3 pro skryté neurony a 4 výstupní neurony (2 ovládající kolečka, 2 aktivující přední a zadní led). Formou jsou podobné předchozím modelům robotů.

Fitness funkce je vyhodnocena po nasazení do robotů a provedení simulace, vlastní fitness je pak průměr z 15 běhů. Ve vyznačených místech se roboti nabíjí, což trvá daný čas a roboti s lepší efektivitou přesunů z jednoho místa do druhého stihnout cestu tam a zpět mnohem rychleji.

Výsledky prokazatelně ukazují úspěšné použití evolučních strategií na optimalizaci chování robotického hejna. Pro většinu prostředí dokázali najít efektivní řešení a jak lze vidět na nákresech, dráhy se optimalizují ve dvousměrnou cestu pro přesun z A do B.

3. Simulátor

Součástí bakalářské práce bylo také naprogramování simulátoru mapy, její vizualizace, implementace všech EA, vše v jazyce C#. Veškeré informace o simulátoru a jeho součástech můžete najít v dokumentaci na přiloženém CD. V této kapitole popíši pouze spuštění, základní objekty simulátoru a aplikované optimalizace.

Části simulátoru

- *SwarmSimFramework.exe* - konzolová aplikace, která obsahuje kód pro EA optimalizaci a simulaci mapy
- *SwarmSimVisu.exe* - program pro vizualizaci, implementovaný ve WPF a C#

Spuštění

Pro spuštění optimalizace *SwarmSimFramework.exe* je potřeba soubor s konfigurací experimentu, soubory s konfigurací pro ES mají koncovku *.es* a v případě DE *.expe*. Jednotlivým EA také odpovídají očekávané argumenty.

- ES - *SwarmSimFramework.exe -es soubor_konfigurací.es*
- DE - *SwarmSimFramework.exe -de soubor_konfigurací.de*

V rámci konfiguračních souborů můžeme nastavit charakteristiky mapy, ohodnocení jednotlivých složek fitness, specifikovat druh či počet robotů, název experimentu a název složky s výstupem. Výstupní složka obsahuje serializované nejlepší jedince vždy po 10 generacích, metadata pro graf (číslo generace, hodnoty fitness), serializované veškeré jedince po 100 generacích. V případě ES mají jedinci svou vlastní podsložku z implementačních důvodů (paralelismus). Populace z poslední generace je ještě serializována do složky spuštění. Do konzole, pak program vypíše základní informace o aktuální generaci.

Pokud si chceme prohlédnout některé z chování vizuálně, spustíme program *SwarmSimVisu.exe*. Kde je připraveno grafické rozhraní, kde pomocí tlačítek navolíme vybraný scénář, nastavení mapy a soubory se serializovaným řízením robota. Poté je možné danou simulaci spouštět a zastavovat, při zastavené simulaci pravým klikem na robota lze zobrazit jeho podrobné informace.

Optimalizace

Simulace mapy patří mezi časově nejvíce náročnou část. Pro její zrychlení jsem použil paralelního programování, jeho přístup se liší podle EA. Za použití profileru jsem našel, že nejvíce času simulace zabralo počítání jednotlivých průsečíků pro senzory, efekторы a entity samotné. Pro optimalizaci počtu průsečíků jsem implementoval vlastní datovou strukturu *SpatialHash*.

Rozdělení ES na části, které jsou paralelně zpracované, je vcelku přirozené, protože každý jedinec používá pro tvorbu potomka mutace odvozeného z sebe samotné. Tím pádem můžeme od sebe oddělit jednotlivé jedince a nemusí sdílet žádnou paměť. U DE bylo rozdělení poněkud složitější, protože v rámci běhu vybírá náhodně z celé populace. Rozhodl jsem se, že oddělím simulace mapy, která probíhá pro nově vzniklého potomka a na její základě se hodnotí jeho fitness. Takže pro každého člena původní populace vznikne nezávislý proces, který vybere z aktuální populace 3 jedince (pouze čtení) a pak nově vzniklého jedince vloží do thread safe datové struktury (list z knihovny `System.Collections.Concurrent`). Po dokončení všech procesů se přejde k další generaci. Použití paralelního zpracování znemožňuje přesné zopakování experimentů, zkoušel jsem experimenty pouštět na rozličných strojích a výsledky řádově odpovídají.

Nějaké větší detaily, CPU, stejný seed pro všechno, ale nemůžu ovlivnit pořadí volání random number

`SpatialHash` rozděluje mapu na síť malých čtverečků. Každá entita (mimo roboty) je uvedena ve všech čtverečcích do kterých zasahuje. Pro počítání kolizí dostane potenciálně kolidující těleso od `SpatialHash` množinu obsahující všechny entity zasahující do stejných čtverečků jako potenciálně kolidující těleso. Jedinou výjimku tvoří roboti, neboť se často přesouvají po mapě a ve `SpatialHash` by neustále měnili pozici. Operace spojené s častým pohybem byly více náročné než počítat průsečíky se všemi roboty, takže roboti jsou uloženi v klasickém listu.

Použití

Pro jednotlivé objekty na mapě jsem vytvořil obecný objektový návrh, který umožňuje jednoduché přidání vlastních objektů. Případně používat pouze simulaci na mapě pro jiné účely než optimalizaci chování robotů. Návrh nových evolučních algoritmů.

Ještě něco přidat?

Nějaký obrázky?

Jak moc má tohle má být podrobný?

4. Experimenty

Všechny práce zmíněné v úvodní kapitole používají evoluční algoritmy k vytvoření řízení chování homogenního robotického hejna, tzn. s jedním druhem robotů. V následující kapitole podrobně popíši postup hledání optimální chování pro heterogenního hejna. Optimalizaci jsem navrhl a otestoval na třech rozličných scénářích.

Pracovní názvy scénářů:

1. Wood Scene - zpracování dřeva
2. Mineral Scene - přetvoření minerálů na palivo
3. Competitive Scene - soubojový scénář

Hlavní motivací při tvorbě scénářů bylo vytvořit obtížnější úkoly než se obvykle používají jako například: shlukování, vyhýbání překážkám, atp. Navrhnout je natolik komplexně, aby nebylo možné, že část hejna se nebude podílet na jeho plnění. Také jsem volil scénáře, aby se přiblížily situacím z reálného světa. Každému z nich jsem věnoval samostatnou kapitolu, která zahrnuje popis hlavního úkolu scénáře, seznam robotů i s jejich senzory a efekty, způsob hodnocení fitness, rozdělení do podúkolů s průběhem fitness u ES a DE, vizualizaci a rozbor chování nejlepšího jedince.

Pro řešení problému jsem navrhl řadu postupů, proto v tomto odstavci zmíním ty nejvíce přímočaré a slibné, které se ovšem ukázaly jako neúspěšné. V kapitolách zabývajících se konkrétními scénáři už budu pouze popisovat jen konečné, úspěšné postupy.

Nedostatečný se ukázal pokus provádět evoluci pro fitness hlavního úkolu scénáře. Konkrétně pro Wood Scene počet natěženého a uskladněného dřeva, pro Mineral Scene objem vytvořeného paliva, pro kompetitivní scénář zbylé body zdraví a udělené poškození. Většina hodnocení náhodných chování byla rovna nule, proto EA nedostaly dostatek informací k vhodné exploraci a díky malé pravděpodobnosti vygenerování chování alespoň částečně řešící hlavní úkol nedocházelo ani k exploataci. Což mělo za důsledek neefektivní DE a ES, takže ani jeden z EA nedošel k úspěšnému řešení.

Posun zaznamenala více obecná fitness i když sama o sobě také nedosáhla do kategorie úspěšných postupů. Do fitness jsem zahrnul i menší pozitivní znaky, které byly součástí hlavnímu úkolu. Například jsem záporně ohodnotil pokusy o pohyb končící kolizí, kladně počet nalezených entit či vhodných objektů v kontejnerech, aktuální stav paliva. Optimalizovaná chování opravdu zaznamenala posun. Ovšem oba EA obtížně hledaly cestu z lokálního optima a ve většině případů optimalizovali pouze jednoduché části úkolu. I přes přidávání složitějších matematických funkcí do fitness nebyly schopny dosáhnout uspokojivého řešení hlavního úkolu scénáře.

Nějak pojmenovat

Pro finální řešení jsem zvolil metodu, kterou nazývám metodou podúkolů. U každého scénáře podrobně popíši její průběh a nastavení, zde pouze nastíním

základní myšlenku. Rozdělil jsem hlavní cíl na několik menších podúkolu (meta-úkolů). Každému z nich vytvořím fitness funkci odpovídající nutné části hlavního cíle. Fitness metaúkolů jsem navrhoval, tak aby necílila na již optimalizované úkony a v každém podúkolu jsem se vždy soustředil pouze na jeden jednoduchý úkon. Díky tomuto principu jsem dosáhl mnohem vyšší odolnosti proti uvíznutí v lokálním minimu. Explorace se tímto procesem také zlepšila, protože hlavní cíl závisí na podúkolech a pokud bylo chování rozmanité a úspěšné, přenesly se tyto vlastnosti i dále. Poté jsem generaci úspěšnou v průzkumu optimalizoval na sbírání materiálů pouze požadované barvy a takto jsem rozdělval až k finálnímu úkolu scénáře.

Každý robot má připojen paměťový slot, neboť roboti s nimi dosahovali ve všech úkolech znatelně lepších výsledků a pomáhaly vytvářet složitější chování.

4.1 Použité technologie

Tuto kapitolu věnuji klíčovým technologiím, jenž jsem použil pro modelování řešeného problému a optimalizaci náhodných chování. Pro ovládání robotů jsem zvolil v poslední době velmi oblíbené *neuronové sítě*, které se často používají v kombinaci s EA. Jednomu jedinci odpovídá jedna neuronová síť ovládající všechny části robota. Tyto neuronové sítě si lze představit jako vektor reálných čísel, což je vhodná reprezentace genotypu pro EA.

Reprezentace Chování - neuronové sítě

Pro reprezentaci jedinců v oblasti robotiky, rozpoznávání obrazů a dalších oblastí umělé inteligence se v poslední době používají nejčastěji neuronové sítě. Neuronová síť se strukturou podobá neuronovým sítím v mozku. Základní síť se skládá z jednotlivých neuronů, které se v kontextu informatického světa nazývají *perceptrony*. Samostatný perceptron je sám o sobě také neuronovou sítí, ale většinou se propojují do složitějších struktur. Perceptron lze definovat podle (Marsalli) následovně.

Definice 1 (Perceptron). *Perceptron je funkce z $\mathbb{R}^n \rightarrow \mathbb{R}$, která je dána následujícím předpisem: $Y = S(\Theta + \sum_{i=0}^n w_i x_i)$, kde pro $i \leq n$ x_i je i ý prvek vstupního vektoru, w_i se označuje jako váha a většinou w_i se bere z \mathbb{R} . Θ se nazývá práh (bias) a slouží jako váha s konstantním vstupem 1. $S(X)$ je aktivační funkce: $\mathbb{R} \rightarrow \mathbb{R}$ a Y se obvykle označuje jako výstup perceptronu.*

Jednovrstvou neuronovou sítí pak myslíme n perceptronů, tedy funkci $\mathbb{R}^n \rightarrow \mathbb{R}^n$, kde i tou složku výstupního vektoru dostaneme aplikací funkce odpovídající i temu perceptronu na vstupní vektor.

Pokud zapojíme z výstupu jednoho perceptronu na vstup jiného, vznikne *vícetvrstvá neuronová síť*. Což znamená, že podmnožiny výstupů z první vrstvy neuronů neurčují přímo výstup, ale jsou opět zvoleny jako vstupní vektory pro další jednovrstvou neuronovou síť. Tímto postupem můžeme vytvářet velmi komplexní struktury.

Skrytá vrstva (hidden layer) je taková jednovrstvá neuronová síť, jejíž výstup (resp. vstup) je pouze vstupem (resp. výstup) jiných perceptronů.

Pro mé účely se jsem testoval řadu různých variant neuronových sítí, ale nej-

Přidat část o aktivačních funkcích

přeformulovat??

více se mi osvědčilo následující nastavení, které poskytovalo uspokojivé výsledky a rozumné časové nároky.

Jako aktivační funkce jednotlivých perceptronů se mi nejvíce osvědčila často používaná funkce hyperbolického tangentu se změněným oborem hodnot pro konkrétní výstup.

V rámci testování jsem zvolil jednoduchou architekturu jednovrstvé neuronové sítě, což se ukázalo jako dostatečné pro uspokojivé řešení jednotlivých scénářů. Jejich architektura je následující. Pro každé reálné číslo, které očekává robot jako vstup pro efektor, byl připojen perceptron do kterého vstupuje vektor reálných čísel odpovídající vektoru všech hodnot přečtených ze senzorů. Pro dosažení lepších řešení by zde bylo možné nasadit NEAT algoritmus či hledat více specifitější architektury. Případně vyzkoušet vliv vícero vrstev.

Přidat
do dis-
kuze

Evoluční algoritmy

Neuronovou síť si lze představit jako množinu vektorů, kde jeden perceptron odpovídá vektoru reálných čísel (vah vstupů + práh $v = (x_0, x_1 \dots x_n, \Theta)$). V kontextu evolučních algoritmů se pro optimalizaci vektorů reálných čísel nejčastěji používají ES a DE, I z tohoto důvodu jsem zvolil zmíněné algoritmy jako zástupce pro optimalizaci chování heterogenní skupiny robotů. Oba zmíněné algoritmy důkladně popisují v kapitole 1.4 a 1.5 a má implementace se od popisu v úvodu liší pouze v malých detailech. Do detailu si je lze prohlédnout v příložené dokumentaci a kódu.

V rámci testování jsem vyzkoušel mnoho různých nastavení parametrů EA. V tabulce 4.1 jsou uvedeny nakonec použité parametry, které dosahovali v experimentech největších úspěchů. Jedná se o tradičně používané parametry, osvědčené v řadě optimalizačních problémů.

Popsat
co jed-
notlivé
para-
metry
dělají??

diferenciální evoluce	
F:	0,8
CR:	0,5
evoluční strategie	
alpha	0,05
sigma	0,1

Tabulka 4.1: Nastavení parametrů u EA

4.2 Wood Scene experiment

Vzorem Wood Scene scénáře byla těžba dřeva, představme si dřevorubce s motorovou pilou a silné dělníky nakládající zpracované stromy do transportérů a svázející materiál na společnou hromadu. Roboti odpovídají těmto lidským rolím, samozřejmě je jejich činnost značně zjednodušena. V obou případech je cílem maximalizovat počet zpracovaného dřeva na daném místě, což vyžaduje od obou druhů agentů spolupráci.


Robotické hejno se ve Wood Scene snaží natěžit a převést, co největší množství dřeva na místo označené rádiovým signálem. Rádiové senzory poskytují robotům sílu signálu a vysílaný kód. Pro místo určené na kupení dřeva je určen unikátní kód 2 a je umístěn doprostřed mapy. Žádný jiný rádiový vysílač vysílající signály s kódem 2 se na mapě nenachází.

Celé hejno čítá 9 robotů, jedná se o dva různé druhy, které se liší velikostí, rychlostí, senzory i efekty. Na začátku experimentu jsou náhodně rozmístěny do středu mapy na stejném místě jako se rozprostírá skladovací prostor. Dále jsou na mapě náhodně umístěny stromy. Robot v kontextu scénáře nazývaný Scout odpovídá „dřevorubci“ v teoretickém vzoru, pohybuje se rychle, má menší rozměry, umí nalezený strom zpracovat na dřevo pro komunikaci má přidělený unikátní kód 0. Oproti tomu robot „dělník“ se pohybuje pomaleji, je větší, neumí zpracovávat stromy, ale disponuje nakladačem (vykladačem) a kontejnerem na 5 objektů.


Souhrnně hejno musí strom nalézt, přepracovat na dřevo, poté naložit a odvézt do středu. Celý tento proces zahrnuje typické úkoly pro robotický swarm jako rozproštění, vyhýbání se překážkám, komunikaci mezi jednotlivými agenty, nalezení cesty apod. Z návrhu je zřejmé, že na procesu se musí podílet oba druhy robotů.

V rámci bakalářské práce byla připraven program zajišťující jednoduchou vizualizaci chování robotů. Jeho vizuální výstup můžete vidět na obrázku 4.1. Na ní si vysvětlíme jednotlivé entity nacházející se na mapě. Mapa je ohraničena obdélníkovou hranicí a chová se jako zeď. Zelené kroužky znázorňují stromy, které ještě nebyly objeveny. Objevený strom změní barvu na žlutou. Modře označený prostor je určen pro uskladnění zpracovaného dřeva, roboti jej zaznamenají jako rádiový signál. Hnědá kolečka zastupují pokácené dřevo. V některých podúkolech se objevuje dřevo už při inicializaci, proto ještě neobjevené má tmavší barvu a objevené světlejší. Pro roboty je v tomto prostoru vysílán rádiový signál. Roboti jsou vyplněny červenou barvou, jejich senzory a efekty mají černou barvu. Pro každý rádiový signál je určena jedna unikátní barva s alfa kanálem.

Pro potvrzení, že scénář není triviálně řešitelný. Bylo vygenerováno tisíc náhodných chování. Hodnoceny byly dle fitness funkce podúkolů kooperace popsány níže. Nejlepší z nich můžete vidět těsně po inicializaci mapy 4.1. Výsledek krátce před 10 000. iterací je zachycen v obrázku 4.2. Největší světlá zelená plocha je volný prostor, kde se mohou roboti pohybovat. Světle růžový kruh je právě rádiové vysílání, protože všichni roboti vysílají současně je barva celkem sytá. Tmavě fialový kruh označuje místo pro uskladnění, obvykle má modrý odstín, ale protože jej překrývají signály robotů zbarvil se do fialové. Na obrázku 4.2 vidíme, že se robotům povedlo jeden strom pokácet a dokonce uložit. Většina velkých robotů se dostala do kolize a menší roboti nedokázali objevit ani pětinu stromů.



Obrázek 4.1: Příklad WoodScene mapy: start náhodného chování



Obrázek 4.2: Příklad WoodScene mapy: po 9000 iteracích náhodného chování

4.2.1 Roboti

Devítičlenné hejno obsahuje 5 Scout robotů a 4 Worker roboty. U každého z robotů popíši jejich efektory a senzory. Pro každý druh robota je připravena jedna shodná neuronová síť. Jedinec odpovídá vektoru vah neuronové sítě. Pokud v rámci experimentu optimalizují chování více druhů robotů, jedinec jsou dva vektory vah pro každý druh robota jedna neuronová síť. Proto fitness funkce hodnotí jejich výsledné snažení dohromady a evoluční operátory pracují nad celou dvojicí. Podívejme se na jednotlivé druhy podrobně.

Scout robot

Jedná se o robota, který má na starosti průzkum mapy a kácení nalezených stromů. Na zpracování dřeva používá efektor, nazýváme jej refaktor, který má podobu úsečky a vyčnívá z čela robota. Pro zpracování musí refaktor kolidovat se stromem v mapě, poté je strom prohozen za entitu dřeva. Aby mohl komunikovat má přidělený rádiový signál s kódem 0, při jeho vysílání přidá na mapu signál jako kruh se středem odpovídající pozici robota. Jedná se o menšího robota, oproti Worker robotovi je rychlejší a jeho senzory mají větší dosah. Tabulka 4.2 obsahuje základní charakteristiky, počty a dosahy jednotlivých senzorů a efektorů.

Scout Robot	
Tvar:	<i>Kruh</i>
Poloměr:	2,5
Název:	<i>WoodCutterM</i>
Velikost kontejneru:	0
Efektory	
Motor:	<i>Dvoukolečkový</i>
Maximální rychlost:	3
Kód rádiového signálu:	0
Poloměr signálu:	200
Refaktor:	<i>Strom \Rightarrow Dřevo</i>
Dosah refaktoru:	10
Počet paměťových slotů:	10
Obsah slotu:	<i>float</i>
Senzory	
Počet line senzorů:	3
Délka line senzorů:	50
Orientace line senzorů:	0°, 45°, -45°
Poloměr type senzoru:	50
Poloměr rádiového přijímače:	100
Počet touch senzorů:	8
Lokátor senzor	

Tabulka 4.2: Wood Scene - Scout robot popis

Worker robot

Worker robot se stará o manipulaci a následný transport objektů na mapě. Pohybuje se pomaleji než Scout a také je o něco rozměrnější. Picker, úsečkový efektor sloužící pro nakládání a vykládání objektů, funguje na podobném principu jako refaktor pro naložení musí kolidovat s objektem a pro vyložení s ním nesmí nic kolidovat. Ke komunikaci mu byl vyhrazen rádiový signál s kódem 1. Sebrané objekty ukládá do kontejneru, kam se vejde celkem 5 entit a vykládat umí pouze entitu na vrchu. Tabulka 4.3 popisuje další podrobnosti.

Worker Robot	
Tvar:	<i>Kruh</i>
Poloměr:	5
Název:	<i>WoodWorkerM</i>
Velikost kontejneru:	5
Efektory	
Motor:	<i>Dvoukolečkový</i>
Maximální rychlost:	2
Kód rádiového signálu:	0
Poloměr signálu:	200
Dosah pickeru:	10
Počet paměťových slotů:	10
Obsah slotu:	<i>float</i>
Senzory	
Počet line senzorů:	3
Délka line senzorů:	30
Orientace line senzorů:	0°, 45°, -45°
Poloměr rádiového přijímače:	100
Počet touch senzorů:	8
Lokátorový senzor	

Tabulka 4.3: Wood Scene - Worker robot popis

4.2.2 Vyhodnocování Fitness

Fitness funkce pro ohodnocení WoodScene scénáře probíhá vždy až na konci simulace. I když se úspěšnost v podúkolech vždy posuzuje jinak, celou fitness funkci lze shrnout do následujícího cílů. Roboti jsou odměňováni za:

1. *nalezené stromy* - stromy o které zavadil line senzor
2. *pokácené stromy* - stromy, které refaktor změnil
3. *sebrané dřevo* - zpracované dřevo, které mají roboti uvnitř kontejnerů
4. *uskladněné dřevo* - dřevo, které dovezli na vyznačené místo

Trestání za:

1. *kolize* = počet pokusů o pohyb při kterém by došlo ke kolizi
2. *sebrané entity mimo dřevo* - počet entit v kontejnerech, které nejsou zpracované dřevo

4.2.3 Podúkoly

Rozdělil jsem hlavní cíl na následující podúkoly. Jejich obtížnost postupně roste a finální metaúkol už odpovídá řešenímu problému. Pro ES a DE jsem použil stejné, abych bylo možné porovnat jejich fungování.

1. vygenerování robotů = Na začátku je vygenerováno chování robotů naprosto náhodně. Pro každého robota, je vygenerována náhodná jednovrstvá neuronová síť.
2. učení chůze = Pro oba roboty je velmi důležité, aby se pohybovali bez kolizí po celé mapě a objevovali, co největší prostor. Roboti jsou vyvíjeni odděleně a fitness se soustředí na počet kolizí (záporným ohodnocením) a na nalezené stromy (kladným ohodnocením).
3. těžba stromů = Scout roboty, kteří se už obstojně po mapě pohybují, je třeba naučit kácet stromy. Proto dalším cílem ve fitness funkci je počet pokácených stromů. Nicméně stále také na počet stromů nalezených.
4. převoz dřeva = Správně pohybující chceme naučit sbírat vytěžené dřevo. Fitness hodnotí počet sebraného dřeva, případně i uskladněné dřevo. Na těchto mapách jsou už na začátku připraveny pouze entity zpracovaného dřeva.
5. kooperace = V posledním experimentu, se hodnotí pouze sebrané a uskladněné dřevo. A evolvují se oba druhy robotů současně.

U každého experimentu uvedu myšlenku, tabulku s přesným nastavením a poté graf s průběhem fitness jednotlivých EA plus jejich vzájemné porovnání. ES v rámci mutačních operátorů vytváří několik zmutovaných jedinců a na základě jejich fitness utváří potomka. Vyhodnocování fitness je časově nejnáročnější výpočet, protože se musí probíhat na mapě celá simulace. Aby časy běhu DE a ES byly srovnatelné, odpovídá velikost populace u DE, velikosti populace krát počet mutovaných jedinců u ES. Při porovnání EA zobrazuji průměrné hodnoty fitness jedinců v rámci daného podúkolů.

nebylo
by lepší
slovo
než
myš-
lenku

Scout chůze - nastavení experimentu


Nejdříve jsem se zaměřil na schopnost pohybu jednotlivých robotů po mapě. Oddělil jsem oba druhy od sebe, protože díky rychlejšímu pohybu Scout robotů EA optimalizovalo pouze jejich pohyb. Roboti byli oceněni za nalezené stromy, tato fitness je nutná rozprostřít se po mapě. Následuje tabulka s nastavením fitness a EA.

Nastavení mapy a EA	
Roboti:	<i>Scout</i> – 5
Počet generací:	1000
Počet iterací map	1000
Velikost generace(DE)	200
Počet jedinců(ES)	10
Počet mutovaný potomků(ES)	20
Elitismus(ES)	<i>Ano</i>
Elitismus(DE)	<i>Ne</i>


Fitness funkce	
Hodnota nalezeného stromu	10
Ostatní hodnoty:	0
Počet stromů:	300
Počet už pokácených stromů	100

Tabulka 4.4: Scout chůze - nastavení experimentu

Výsledky experimentu ilustrují grafy na další stránce. Jednotlivé průběhy fitness na obrázcích 4.4a a 4.4b ukazují střední hodnotu fitness a její rozptyl v závislosti na generaci, jedinci jsou kvůli přehlednosti sloučeni po 10 generacích. V obou případech docházelo k největšímu růstu do 200 generace (v grafech 20). Oba EA lze označit jako úspěšné, protože vygenerovaná chování objevila více než 50% stromů na mapě, v případě DE dokonce více dvě třetiny. U ES jsem nepoužíval elitismus, proto křivka více osciluje než je tomu u DE.



Obrázek 4.3: Scout chůze - porovnání průměrné fitness ES a DE



Obrázek 4.4: Scout chůze - průběh fitness

Worker chůze - nastavení experimentu


Worker chůze aplikuje podobný postup jako v předchozím experimentu na Worker roboty. Jen jsem nehodnotil počet nalezených stromů, ale do každé mapy jsem umístil už zpracované stromy. Roboti tedy byli oceněni za nalezení právě tohoto dřeva. Opět fitness funkce nutí roboty, co nejvíce se rozprostřít po mapě a navíc ještě vyhýbat se nepokáceným stromům.

Nastavení mapy a EA	
Roboti:	<i>Worker</i> – 4
Počet generací:	1000
Počet iterací map	1000
Velikost generace(DE)	200
Počet jedinců(ES)	10
Počet mutovaný potomků(ES)	20
Elitismus(ES)	<i>Ano</i>
Elitismus(DE)	<i>Ne</i>

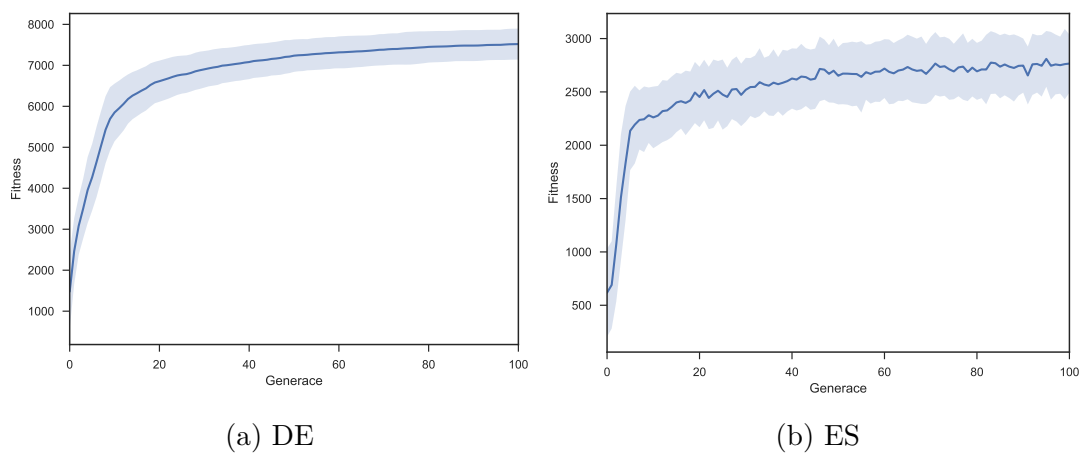
Fitness funkce	
Hodnota nalezeného pokáceného stromu	10
Ostatní hodnoty:	0
Počet stromů:	100
Počet už pokácených stromů	300

Tabulka 4.5: Worker chůze - nastavení experimentu

DE dokázal už ve 200. generaci najít většinu zpracovaného dřeva na mapě, jak můžeme vidět na grafu 4.6a. ES neoptimalizovalo v tomto případě příliš rychle a uvízlo v lokálním optimu, jak ukazuje graf 4.6b od 200. generace. Nejlepší jedinec optimalizovaný pomocí DE byl schopen nalézt až 3x zpracovaného než ten pomocí ES. Nutno dodat, že náhodná pozice se entit na mapě se liší pro ES a DE. Zkoušel jsme, proto měnit seed u generátoru náhodných čísel a výsledky odpovídaly grafům 4.6 i 4.5..



Obrázek 4.5: Worker chůze - porovnání průměrné fitness ES a DE



Obrázek 4.6: Worker chůze - průběh fitness v rámci generací

Scout kácení - nastavení experimentu


Dalším úkolem pro Scout robota bylo nalezené stromy pokácet. Použil jsem tedy optimalizované neuronové sítě z experimentu Scout chůze a tentokrát přidal do fitness pozitivní body za pokácené stromy. Refaktor je o mnoho kratší než line sensory, proto pro kácení musí robot ke stromu přijet blíže. Abych ještě více vylepšil pohyb po mapě, tak každá kolize byla potrestána negativním bodem do fitness. Přesné nastavení obsahuje následující tabulka.

Nastavení mapy a EA	
Roboti:	<i>Scout</i> – 5
Počet generací:	1500
Počet iterací map	1000
Velikost generace(DE)	200
Počet jedinců(ES)	10
Počet mutovaný potomků(ES)	20
Elitismus(ES)	<i>Ano</i>
Elitismus(DE)	<i>Ne</i>


Fitness funkce	
Hodnota nalezeného stromu	1000
Hodnota pokáceného stromu	10000
Hodnota kolize	–1
Ostatní hodnoty:	0
Počet stromů:	400
Počet už pokácených stromů	0

Tabulka 4.6: Scout kácení - nastavení experimentu

Dále můžete vidět grafy popisující průběh fitness u DE, ES a porovnání jejich průměrné fitness. Z 4.8a můžeme vyčíst, že použité DE více cílí na exploataci a ES na exploraci. DE jsou díky tomu mnohem náchylnější k uvíznutí v lokálním optimu. Fitness se v tomto případě skládá ze dvou složek, pro jedince bylo mnohem jednodušší stromy objevovat a náhodou nějaké pokácet. V prvních 650 generacích DE se tedy drží tento trend a pak se objeví jedinci, kteří cílí na kácení. Toto chování se rychle rozšířilo a fitness celé populace okolo 700. generace prudce vzrostla. Zatímco fitness v ES rostla postupně, ale nedosáhla tak vysoké úrovně jako DE. Nejlepší jedinci pokácí více než 60% stromů.



Obrázek 4.7: Scout kácení - porovnání průměrné fitness ES a DE



Obrázek 4.8: Scout kácení - průběh fitness v rámci generací

Worker sbírání - nastavení experimentu


Worker v rámci zadání musí řešit více složitý úkol než Scout robot. Celý proces uložení se skládá nejdříve z nalezení dřeva, naložení, poté přesunu místa pro skladování a nakonec vyložení. Optimalizace fungovala lépe po rozdělení na část nakládání, kterou se zabývá tento experiment a na část vykládání, na kterou se podíváme později. Ve fitness jsem se soustředil na správné entity v kontejneru a na jejich počet. Abych nezhodil dobré chování, které dokáže dřevo i ukládat, za uložení dřeva dostali roboti také pozitivní body. Níže můžete vidět tabulku s konkrétním nastavením.

Nastavení mapy a EA	
Roboti:	<i>Worker</i> – 4
Počet generací:	2000
Počet iterací map	1000
Velikost generace(DE)	200
Počet jedinců(ES)	10
Počet mutovaný potomků(ES)	20
Elitismus(ES)	<i>Ano</i>
Elitismus(DE)	<i>Ne</i>


Fitness funkce	
Hodnota nalezeného pokáceného stromu	100
Hodnota uloženého dřeva	1010
Hodnota dřeva v kontejneru	1000
Hodnota jiné entity v kontejneru	–100
Hodnota kolize	–1
Ostatní hodnoty:	0
Počet stromů:	200
Počet už pokácených stromů	200

Tabulka 4.7: Worker sbírání - nastavení experimentu

V grafech 4.10, 4.9 je vidět, že roboti dokázali maximálně naplnit kontejnery zpracovaným dřevem, v případě DE už po 250. generaci zvládala tento úkol celá populace. Chování optimalizované ES mají mnohem větší rozptyl díky vysoké exploraci, ale i její nejlepší jedinci zvládli maximální naplnění již kolem 250. generace.



Obrázek 4.9: Worker sbírání - porovnání průměrné fitness ES a DE



Obrázek 4.10: Worker sbírání - průběh fitness v rámci generací

Worker ukládání doprostřed - nastavení experimentu


Ukládání zpracovaného dřeva byl poslední experiment, který plnili Worker roboti samostatně. Zde jsem se soustředil na celý úděl Worker robota a využil už optimalizovaných neuronových sítí na sbírání zpracovaného dřeva z předchozího experimentu. Nejvyšší odměnu roboti získávali za uskladnění dřeva a minoritní odměny za vhodné chování dle předchozích fitness. Vlastním nastavení odpovídá tabulce 4.8.

Nastavení mapy a EA	
Roboti:	<i>Worker</i> – 4
Počet generací:	2000
Počet iterací map	2000
Velikost generace(DE)	200
Počet jedinců(ES)	10
Počet mutovaný potomků(ES)	20
Elitismus(ES)	<i>Ano</i>
Elitismus(DE)	<i>Ne</i>


Fitness funkce	
Hodnota nalezeného pokáceného stromu	100
Hodnota uloženého dřeva	1000
Hodnota dřeva v kontejneru	100
Hodnota jiné entity v kontejneru	–100
Hodnota kolize	–1
Ostatní hodnoty:	0
Počet stromů:	200
Počet už pokácených stromů	200

Tabulka 4.8: Worker ukládání doprostřed - nastavení experimentu

Lokace skladovacího místa působila robotům velké obtíže, proto růst fitness (4.12a, 4.12b) byl mnohem mírnější než u předchozích experimentů. DE dokázala už optimalizované chování rychleji vylepšovat narozdíl od ES, která doplácí na velkou míru exploração viz. 4.11. Nejlepší jedinci jsou ovšem už schopni plnit obstojně hlavní úkol Worker robotů. Objevila se obtíž s efektivním urovnáním zpracovaného dřeva na skladovací místo. Pokoušel jsem se tento problém řešit, přidáním kladných bodů za menší vzdálenost mezi středem skladovacího místa a uloženým dřevem. Nesáhl jsem, však lepších výsledků než v tomto experimentu.



Obrázek 4.11: Worker ukládání doprostřed - porovnání průměrné fitness ES a DE



(a) DE

(b) ES

Obrázek 4.12: Worker ukládání doprostřed - Průběh fitness v rámci generací

Kooperace hlavní úkol - nastavení experimentu


V rámci posledního úkolu jsem složil už optimalizovaná chování dohromady, abych vytvořil heterogenní hejno řešící problém Wood Scene scénáře. Spojoval jsem náhodné chování pro Scout robota s náhodným u Worker robota, aby se našla nejlepší jejich kombinace, tak bylo nutné navýšit počet generací na 4000. Fitness funkce(4.9) byla v tomto případě průnik posledních experimentů Worker ukládání doprostřed a Scout kácení.

Nastavení mapy a EA	
Roboti:	<i>Scout</i> – 5, <i>Worker</i> – 4
Počet generací:	4000
Počet iterací map	2000
Velikost generace(DE)	200
Počet jedinců(ES)	10
Počet mutovaný potomků(ES)	20
Elitismus(ES)	<i>Ano</i>
Elitismus(DE)	<i>Ne</i>


Fitness funkce	
Hodnota nalezeného pokáceného stromu	100
Hodnota uloženého dřeva	1000
Hodnota dřeva v kontejneru	100
Hodnota jiné entity v kontejneru	–100
Hodnota kolize	–1
Ostatní hodnoty:	0
Počet stromů:	400
Počet už pokácených stromů	0

Tabulka 4.9: Kooperace hlavní úkol - nastavení experimentu

Na 4.14 lze pozorovat, že pro ES bylo velmi obtížné skládat už úspěšné chování do lepších celků a velmi osciluje 4.14b. ES uškodilo agresivní prohledávání prostoru a DE díky své architektuře vytěžilo z optimalizovaných chování maximum 4.14a. Nejlepšímu jedinci se budeme věnovat podrobněji v další kapitole.



Obrázek 4.13: Kooperace hlavní úkol - porovnání průměrné fitness ES a DE



Obrázek 4.14: Kooperace hlavní úkol - průběh fitness v rámci generací

4.2.4 Výsledky Experimentu

Výsledkem posloupnosti všech podúkolů vzniklo poměrně velmi komplexní chování. Finální neuronové sítě ať u Worker robotů, či Scout robotů se zvládají vyhýbat překážkám. Scout roboti kácí stromy, které naleznou. Worker roboti nakládají zpracované dřevo, pokud na něj narazí, když zachytí signál úložiště, tak vyloží aktuální náklad. Některá chování byla také schopna předejít zaseknutí o nějaký shluk objektů, pokud byl jejich pohyb vpřed neúspěšný, tak po několika pokusech roboti vycouvali a vydali se cestou okolo kritického místa. U většiny se také objevilo použití rádiových signálů jako prostředku pro největší možné rozptýlení po mapě, jakmile zachytí cizí signál vydají se opačným směrem. Průběh fitness jednotlivých podúkolů je zachycena na předchozích grafech 4.4 až 4.12b. V tabulce 4.11 můžete vyčíst průměrné počty nalezených stromů, uskladněného materiálu, apod ze 100 simulací mapy.

Ač se jedná o nejlepší dosažené chování objevují se nějaké nedostatky. Worker robot se občas dostane do pozice, ze které není schopen vyjet, jedná se především o kolize s vícero entitami. Tento problém by mohlo vyřešit použití vícevrstevných sítí či evolučního algoritmu evolvujícího i architekturu sítě. Skládání zpracovaného materiálu po obvodu skladiště není efektivní způsob, jak do něj naskládat maximální množství dřeva. V tomto případě jsem se snažil vylepšit tento nedostatek promítnutím vzdálenosti dřeva od středu skladiště do celkové fitness, ovšem bez znatelného zlepšení v chování. Nejspíše by bylo třeba použít rádiový senzor poskytující více informací o směru k zachycenému signálu.

Inicializační nastavení:


Výška	800
Šířka	1200
Počet iterací	10000
Počet stromů	400
Počet Scout robotů	5
Počet Worker robotů	4

Tabulka 4.10: WoodScene - nastavení mapy pro testovací experiment


Výsledky

Zpracované dřevo zanechané v mapě	225,22
Stromy v mapě	156,22
Z toho nalezené	52,84
Dřevo v kontejnerech	18,48
Uskladněné dřevo	17,56

Tabulka 4.11: WoodScene - výsledky simulace nejlepšího jedince, průměr ze 100 simulací testovacího experimentu



Obrázek 4.15: Nejlepší jedinec - 10000 iterací simulace



Obrázek 4.16: Náhodný jedinec - 10000 iterací simulace

4.3 Mineral Scene

Tento scénář si bere jako inspiraci strategické hry např. Starcraft (Blizzard-Entertainment, 1998) a hypotetické přežití robotů na cizí planetě, kde si budou muset obstarat vlastní nerostné suroviny pro běh. Opět je klíčová spolupráce mezi roboty, kdy roboti mají odlišné určení. Jejich společným cílem je maximalizovat množství vyrobeného paliva.

V mém zjednodušeném scénáři se palivo se vyrábí z minerálů, které jsou náhodně rozmístěny po mapě. Transformaci minerálu na palivo dokáže pouze největší robot Refactor. V mapě se dále nacházejí překážky a volné palivo, které mohou roboti ihned po sebrání použít. V rámci hlavního cíle roboti musí nejdříve nalézt minerál, Refactor jej přeměnit a pak případně předat ostatním robotům.

V Mineral Scene figurují dohromady 3 rozliční roboti, všichni potřebují pro pohyb odlišné množství paliva. Nejmenší robot (Mineral Scout) disponuje pouze senzory k exploraci prostředí a rádiovým vysílačem pro komunikaci se skupinou, opět má unikátní kód jako v předchozím scénáři. Robot střední velikosti (Mineral Worker) se pohybuje o něco pomaleji než Mineral Scout, ale umí přesouvat objekty i více najednou. Robot pro přeměnu minerálu (suroviny na výrobu paliva) označen v simulaci jako Mineral Refactor se přemísťuje nejpomaleji, má možnost přeměnit minerál na palivo.

Je to hodně komplexní asi to zjednoduším

In progress NEKONTROLOVAT předělat na stejný formát jako předchozí kapitola

4.4 Competitive Scene

Poslední ze scénářů se týká soutěže dvou týmů(hejn) ve kterých figurují jeden malý průzkumný robot(Competitive Scout) a jeden větší bojový robot(Competitive Fighter). Úspěšnost týmu je dána zachovanými jednotkami zdraví robotů a uděleným poškozením do nepřátelské skupiny robotů. Competitive Scout se pohybuje značně rychleji než Competitive Fighter, ale uděluje menší poškození. Což lze opět vztáhnout na chování rozdílných skupin nepřátel např. ve strategických hrách, kde se jejich chování adaptuje, co nejlépe na dané prostředí.

4.5 Shrnutí

Závěr

Seznam použité literatury

- ARVIN, F., MURRAY, J., ZHANG, C. a YUE, S. (n.d.). Colias: An autonomous micro robot for swarm robotic applications. *INTERNATIONAL JOURNAL OF ADVANCED ROBOTIC SYSTEMS*, **11**. ISSN 17298806. URL <http://search.ebscohost.com/login.aspx?authtype=shib&custid=s1240919&profile=eds>.
- AZNAR, F., SEMPERE, M., PUJOL, M., RIZO, R. a PUJOL, M. J. (2014). Modelling oil-spill detection with swarm drones. *Abstract & Applied Analysis*, pages 1 – 14. ISSN 10853375. URL <http://search.ebscohost.com/login.aspx?authtype=shib&custid=s1240919&profile=eds>.
- BALCH, T. (2000). Hierarchic social entropy: An information theoretic measure of robot group diversity. *Autonomous robots*, **8**(3), 209–238.
- BASHYAL, S. a VENAYAGAMOORTHY, G. K. (2008). Human swarm interaction for radiation source search and localization. pages 1–8.
- BLIZZARD-ENTERTAINMENT (1998). Starcraft. URL <https://starcraft.com/en-us/>.
- DAVID, P., MIKE, D., REGINA, E., MIKE, H. a CRAIG, L. (2001). Pheromone robotics. *Autonomous Robots*, (3), 319. ISSN 0929-5593. URL <http://search.ebscohost.com/login.aspx?authtype=shib&custid=s1240919&profile=eds>.
- DUARTE, M., COSTA, V., GOMES, J., RODRIGUES, T., SILVA, F., OLIVEIRA, S. M. a CHRISTENSEN, A. L. (2016). Evolution of collective behaviors for a real swarm of aquatic surface robots. *PLoS ONE*, **11**(3), 1 – 25. ISSN 19326203. URL <http://search.ebscohost.com/login.aspx?authtype=shib&custid=s1240919&profile=eds>.
- EIBEN, A. (2015). *Introduction to evolutionary computing*. Springer, Berlin. ISBN 978-3662448731.
- FORTIN, F.-A., RAINVILLE, F.-M. D., GARDNER, M.-A., PARIZEAU, M. a GAGNÉ, C. (2012). Deap: Evolutionary algorithms made easy. *Journal of Machine Learning Research*, **13**(Jul), 2171–2175.
- GOMES, J. C., URBANO, P. a CHRISTENSEN, A. L. (2013). Evolution of swarm robotics systems with novelty search. *CoRR*, **abs/1304.3362**. URL <http://arxiv.org/abs/1304.3362>.
- HOLLAND, J. H. (1976). *Adaptation in Natural and Artificial Systems*, volume 18. URL <http://search.ebscohost.com/login.aspx?authtype=shib&custid=s1240919&profile=eds>.
- IVAN, T., TÜZE, K. a KATSUNORI, S. (2013). Hormone-inspired behaviour switching for the control of collective robotic organisms. *Robotics, Vol 2, Iss 3, Pp 165-184 (2013)*, (3), 165. ISSN 2218-6581. URL <http://search.ebscohost.com/login.aspx?authtype=shib&custid=s1240919&profile=eds>.

- JEVTIĆ, A. a ANDINA DE LA FUENTE, D. (2007). Swarm intelligence and its applications in swarm robotics.
- JONES, S., STUDLEY, M., HAUERT, S. a WINFIELD, A. (2018). *Evolving Behaviour Trees for Swarm Robotics*, pages 487–501. Springer International Publishing, Cham. ISBN 978-3-319-73008-0. doi: 10.1007/978-3-319-73008-0_34. URL https://doi.org/10.1007/978-3-319-73008-0_34.
- MARSALLI, M. Mcculloch-pitts neurons. URL <http://www.mind.ilstu.edu/curriculum/modOverview.php?modGUI=212>.
- MITCHELL, M. (1998). *An introduction to genetic algorithms*. Complex adaptive systems. Cambridge : MIT Press, 1998. ISBN 0-262-13316-4. URL <http://search.ebscohost.com/login.aspx?authtype=shib&custid=s1240919&profile=eds>.
- MONDADA, F., BONANI, M., RAEMY, X., PUGH, J., CIANCI, C., KLAPTOCZ, A., MAGNENAT, S., ZUFFEREY, J.-C., FLOREANO, D. a MARTINOLI, A. (2009). The e-puck, a robot designed for education in engineering. In *Proceedings of the 9th conference on autonomous robot systems and competitions*, volume 1, pages 59–65. IPCB: Instituto Politécnico de Castelo Branco.
- PENDERS, J., ALBOUL, L., WITKOWSKI, U., NAGHSH, A., SAEZ-PONS, J., HERBRECHTSMEIER, S. a EL-HABBAL, M. (2011). A robot swarm assisting a human fire-fighter. *Advanced Robotics*, **25**(1/2), 93 – 117. ISSN 01691864. URL <http://search.ebscohost.com/login.aspx?authtype=shib&custid=s1240919&profile=eds>.
- PROFESSOR MARCO DORIGO (2001). Swarm-bots. URL <http://www.swarm-bots.org>.
- RECHENBERG, I. (1981). "evolutionsstrategie-optimierung technischer systems nach prinzipien der biologischen evolution, stuttgart: Frommannholzboog, 1973. *New York: John Wiley*.
- RUBENSTEIN, M., AHLER, C., HOFF, N., CABRERA, A. a NAGPAL, R. (2014). Kilobot: A low cost robot with scalable operations designed for collective behaviors. *Robotics and Autonomous Systems*, **62**(Reconfigurable Modular Robotics), 966 – 975. ISSN 0921-8890. URL <http://search.ebscohost.com/login.aspx?authtype=shib&custid=s1240919&profile=eds>.
- SHOULSON, A., GARCIA, F., JONES, M., MEAD, R. a BADLER, N. (2011). Parameterizing behavior trees. *Motion in Games*, pages 144–155.
- SPERATI, V., TRIANNI, V. a NOLFI, S. (2011). Self-organised path formation in a swarm of robots. *Swarm Intelligence*, **5**(2), 97–119.
- STORN, R. a PRICE, K. (1997). Differential evolution—a simple and efficient heuristic for global optimization over continuous spaces. *Journal of global optimization*, **11**(4), 341–359.

- TAN, Y. a ZHENG, Z.-Y. (2013). Research advance in swarm robotics. *Defence Technology*, **9**, 18 – 39. ISSN 2214-9147. URL <http://search.ebscohost.com/login.aspx?authtype=shib&custid=s1240919&profile=eds>.
- YALCIN, C. (2008). Evolving aggregation behavior for robot swarms: A cost analysis for distinct fitness functions. pages 1–4.

Seznam obrázků

1.1	obecný evoluční algoritmus - schéma	5
2.1	Cobot2D - nákres robota, zdroj : (Yalcin, 2008)	17
4.1	Příklad WoodScene mapy: start náhodného chování	26
4.2	Příklad WoodScene mapy: po 9000 iteracích náhodného chování	26
4.3	Scout chůze - porovnání průměrné fitness ES a DE	31
4.4	Scout chůze - průběh fitness	31
4.5	Worker chůze - porovnání průměrné fitness ES a DE	33
4.6	Worker chůze - průběh fitness v rámci generací	33
4.7	Scout kácení - porovnání průměrné fitness ES a DE	35
4.8	Scout kácení - průběh fitness v rámci generací	35
4.9	Worker sbírání - porovnání průměrné fitness ES a DE	37
4.10	Worker sbírání - průběh fitness v rámci generací	37
4.11	Worker ukládání doprostřed - porovnání průměrné fitness ES a DE	39
4.12	Worker ukládání doprostřed - Průběh fitness v rámci generací	39
4.13	Kooperace hlavní úkol - porovnání průměrné fitness ES a DE	41
4.14	Kooperace hlavní úkol - průběh fitness v rámci generací	41
4.15	Nejlepší jedinec - 10000 iterací simulace	43
4.16	Náhodný jedinec - 10000 iterací simulace	43

Seznam tabulek

1.1	diferenciální evoluce - souhrnné vlastnosti	10
1.2	evoluční strategie - souhrnné vlastnosti	11
2.1	Porovnání systémů s více agenty	13
2.2	Parameterizing behavior trees, Motion in Games - podoba stromů	15
4.1	Nastavení parametrů u EA	24
4.2	Wood Scene - Scout robot popis	27
4.3	Wood Scene - Worker robot popis	28
4.4	Scout chůze - nastavení experimentu	30
4.5	Worker chůze - nastavení experimentu	32
4.6	Scout kácení - nastavení experimentu	34
4.7	Worker sbírání - nastavení experimentu	36
4.8	Worker ukládání doprostřed - nastavení experimentu	38
4.9	Kooperace hlavní úkol - nastavení experimentu	40
4.10	WoodScene - nastavení mapy pro testovací experiment	42
4.11	WoodScene - výsledky simulace nejlepšího jedince, průměr ze 100 simulací testovacího experimentu	42

Seznam použitých zkratek

Přílohy